



دانشگاه تربیت مدرس

دانشکده علوم ریاضی

پایان نامه دوره کارشناسی ارشد علوم کامپیوتر

بهبود مدل‌های انتشار مبتنی بر مبدل‌های
بینایی برای تولید تصویر

توسط

مصطفی شهبازی دیل

استاد راهنما

دکتر منصور رزقی آهق

تابستان ۱۴۰۵

چکیده

مدل‌های انتشار مبتنی بر مبدل، مانند DiT، کیفیت بالایی در تولید تصویر شرطی ارائه می‌کنند، اما تنظیم دقیق کامل آن‌ها برای دامنه‌ها یا نیازهای جدید از نظر حافظه، زمان آموزش و ذخیره‌سازی پرهزینه است. این پژوهش معماری DuoDiT را برای تنظیم دقیق پارامتر-کارای مدل‌های DiT معرفی می‌کند. در این معماری، بدنه اصلی DiT-XL/2 منجمد باقی می‌ماند و یک شاخه دوم با اندازه پچ کوچک‌تر، ویژگی‌های محلی و ریزدانه را استخراج می‌کند. برای هم‌تراز کردن این شاخه با توکن‌های بدنه اصلی، از مکانیزم توکن کلاس محلی استفاده می‌شود که هر گروه مکانی از توکن‌های ریزدانه را به صورت محتوا-آگاه خلاصه می‌کند. ارزیابی اصلی روی ۵۰ هزار عکس تولید به صورت شرطی روی مجموعه داده ImageNet-1K در وضوح 256×256 انجام شده است. نسخه DuoDiT-200 با 17.95M پارامتر آموزش‌پذیر از مجموع 690.39M پارامتر، به $KID=0.0014$ ، $FID=2.219$ و $LPIPS-Mean=0.7162$ می‌رسد. همچنین در مطالعه انسانی، نمونه‌های DuoDiT در 53.26% مقایسه‌ها نسبت به LightningDiT ترجیح داده شدند. نتایج نشان می‌دهد که افزودن یک مسیر سبک و وضوح بالا می‌تواند بدون آموزش مجدد کامل مدل، کیفیت ادراکی و کارایی تنظیم دقیق را بهبود دهد.

واژه‌های کلیدی: مبدل‌های بینایی، مدل‌های انتشار، ویژگی‌های محلی و سراسری، تجمیع ویژگی، تنظیم دقیق پارامتر-کارا.

فهرست مطالب

ه	فهرست جداول
و	فهرست تصاویر
ح	پیشگفتار
۱	۱ مفاهیم اولیه
۲	۱.۱ شبکه‌های عصبی پیچشی (CNN)
۲	۲.۱ خودکدگذارهای تغییرپذیر (VAE)
۳	۳.۱ شبکه‌های مولد تخصصی (GAN)
۴	۴.۱ مدل‌های انتشار (Diffusion Models)
۵	۱.۴.۱ فرآیند انتشار و معادلات
۶	۵.۱ شبکه‌های عصبی بازگشتی (RNN)
۸	۶.۱ مبدل‌ها
۱۰	۱.۶.۱ مکانیزم توجه
۱۰	۲.۶.۱ لایه رمزگذار و شبکه پیش‌خور
۱۱	۳.۶.۱ تعبیه موقعیت
۱۲	۷.۱ مبدل‌های بینایی

۸.۱	تنظیم دقیق پارامتر-کارا (PEFT)	۱۴
۱.۸.۱	تنظیم پیشوند (Prefix Tuning)	۱۴
۲.۸.۱	تنظیم جانبی (Side-Tuning)	۱۵
۹.۱	مجموعه داده ImageNet	۱۵
۱۰.۱	معیارهای ارزیابی	۱۷
۲	پیشینه پژوهش	۲۰
۱.۲	چارچوب‌های اصلی مدل‌های انتشار	۲۱
۱.۱.۲	مدل‌های DDPM	۲۱
۲.۱.۲	مدل‌های مبتنی بر امتیاز	۲۲
۳.۱.۲	مدل‌های انتشار مبتنی بر SDE	۲۳
۴.۱.۲	نمونه برداری، DDIM و هدایت تولید	۲۴
۲.۲	مدل‌های انتشار مبتنی بر مبدل	۲۴
۱.۲.۲	مدل GenViT	۲۵
۲.۲.۲	مدل U-ViT	۲۶
۳.۲.۲	مدل DiT	۲۸
۳.۲	روندهای تکمیلی در مدل‌های انتشار مبتنی بر مبدل	۳۱
۱.۳.۲	تولید شرطی	۳۳
۲.۳.۲	کاربردها	۳۴
۳.۳.۲	محلیت و ویژگی‌های ریزدانه	۳۵
۴.۲	معماری‌های جریان دوگانه	۳۶
۵.۲	تجمیع ویژگی و توکن	۴۰
۶.۲	روش‌های تنظیم دقیق	۴۳

۴۳	تنظیم دقیق پارامتر-کارا	۱.۶.۲
۴۵	معماری پیشنهادی: DuoDiT	۳
۴۶	معماری مدل	۱.۳
۴۷	تعبیه‌سازی پچ با وضوح بالا	۱.۱.۳
۴۸	روش‌های تجمیع ویژگی	۲.۱.۳
۵۲	روش تجمیع ویژگی با توکن	۳.۱.۳
۵۵	مبدل بینایی به عنوان خبره (ViT as Expert)	۴.۱.۳
۵۵	شرط‌گذاری اختیاری با FiLM	۵.۱.۳
۵۶	ادغام نهایی	۶.۱.۳
۵۷	استراتژی آموزش و تنظیم دقیق	۲.۳
۵۷	مدیریت پارامترهای منجمد و آموزش‌پذیر	۱.۲.۳
۵۸	مقداردهی اولیه با وزن‌های پیش‌آموزش‌دیده	۲.۲.۳
۵۸	تثبیت آموزش با EMA	۳.۲.۳
۵۸	الگوریتم آموزش	۴.۲.۳
۵۸	کارایی پارامتری	۵.۲.۳
۶۰	تابع هزینه	۳.۳
۶۱	جمع‌بندی	۴.۳
۶۲	آزمایش‌ها، نتایج و تحلیل	۴
۶۲	پیکربندی آزمایش	۱.۴
۶۳	جزئیات پیاده‌سازی	۱.۱.۴
۶۳	نتایج کمی	۲.۴
۶۶	نتایج کیفی	۳.۴

۶۷	مطالعه انسانی	۴.۴
۶۷	هزینه محاسباتی و کارایی پارامتری	۵.۴
۶۸	مطالعات حذفی	۶.۴
۶۸	۱.۶.۴ راهبردهای تجميع ویژگی	
۶۹	۲.۶.۴ عمق شاخه دوم	
۶۹	۳.۶.۴ ویژگی‌های شاخه دوم و ضریب CFG	
۷۰	۷.۴ بحث	

۵ نتیجه‌گیری و پیشنهادها

۷۱	۱.۵ خلاصه و دستاوردها
۷۲	۲.۵ پیشنهادهایی برای پژوهش‌های آینده

کتاب‌نامه

فهرست جداول

۱۶	۱.۹.۱ اطلاعات آماری ImageNet
۲۵	۲.۱.۱ مقایسه چارچوب‌های اصلی مدل‌های انتشار
۴۰	۲.۴.۲ مقایسه معماری‌های جریان دوگانه
۶۰	۳.۲.۱ تحلیل پیچیدگی مدل
۶۴	۴.۱.۱ خلاصه تنظیمات آموزش و نمونه‌برداری
۶۵	۴.۲.۲ مقایسه کمی اصلی
۶۵	۴.۲.۳ آمار تجمعی FID کلاسی
۶۷	۴.۴.۴ نتایج مطالعه ترجیح انسانی
۶۸	۴.۵.۵ مقایسه هزینه محاسباتی
۶۸	۴.۶.۶ مطالعه حذفی راهبردهای تجمیع
۶۹	۴.۶.۷ مطالعه حذفی عمق شاخه دوم
۶۹	۴.۶.۸ مطالعه حذفی شاخه دوم و CFG

فهرست تصاویر

۵	۱.۴.۱ شمای کلی فرآیند انتشار
۷	۱.۵.۲ معماری شبکه عصبی بازگشتی
۸	۱.۵.۳ ساختار داخلی واحد LSTM
۹	۱.۶.۴ ساختار کلی معماری مبدل
۱۴	۱.۷.۵ معماری مبدل بینایی
۲۶	۲.۲.۱ معماری GenViT
۲۸	۲.۲.۲ معماری U-ViT
۲۹	۲.۲.۳ معماری DiT
۳۰	۲.۲.۴ معماری DiffiT
۳۱	۲.۲.۵ معماری LaVin-DiT
۳۲	۲.۳.۶ روش کوانتیزاسیون در Q-DiT
۳۵	۲.۳.۷ معماری DiT-3D
۳۶	۲.۴.۸ تجمیع چندوضوحی در HRNet
۳۸	۲.۴.۹ معماری دوجریانی CrossViT
۳۹	۲.۴.۱۰ راهبردهای ادغام ویژگی در CrossViT
۴۲	۲.۵.۱۱ ماژول توجه متقابل در CrossViT

۴۷	۳.۱.۱ نمای کلی معماری پیشنهادی مبتنی بر توکن‌های کلاس محلی
۴۹	۳.۱.۲ تجمیع ویژگی با پروژکشن خطی
۵۱	۳.۱.۳ مقایسه Min Pooling و Max Pooling
۵۳	۳.۱.۴ مکانیزم توکن کلاس محلی
۵۶	۳.۱.۵ بلوک شرط‌گذاری FiLM
۶۶	۴.۳.۱ نمونه‌های تصویری DuoDiT-200

پیشگفتار

یادگیری ماشین به عنوان یکی از ارکان بنیادین هوش مصنوعی مدرن، در دهه‌های اخیر پیشرفت‌های مهمی را در نحوه تعامل سامانه‌های محاسباتی با داده‌ها رقم زده است. این شاخه از علم که بر آماره، بهینه‌سازی و یادگیری از نمونه‌ها استوار است، به سیستم‌ها امکان می‌دهد الگوهای پنهان را بدون طراحی صریح همه قواعد تصمیم‌گیری استخراج کنند [۳۴، ۵۹]. با افزایش حجم داده‌ها و توان محاسباتی، یادگیری عمیق به چارچوب غالب بسیاری از کاربردهای هوش مصنوعی تبدیل شد و شبکه‌های عصبی عمیق توانستند در حوزه‌هایی مانند پردازش زبان طبیعی، تشخیص گفتار و بینایی ماشین عملکردی بسیار رقابتی ارائه دهند [۵۹، ۱۶]. در بینایی ماشین، موفقیت شبکه‌های عصبی پیچشی در استخراج ویژگی از تصویر، نقطه شروع مهمی برای توسعه سامانه‌های دیداری مدرن بود و بعدها معماری‌های مبتنی بر مبدل نیز این مسیر را گسترش دادند [۳۴، ۱۶].

بینایی ماشین، به عنوان یکی از مسیرهای اصلی کاربرد هوش مصنوعی در داده‌های بصری، از وظایف تحلیلی مانند طبقه‌بندی تصویر و تشخیص اشیا به سمت وظایف مولد نیز گسترش یافته است [۱۲، ۶]. مدل‌های مولد نه تنها محتوای بصری را بازنمایی می‌کنند، بلکه می‌توانند نمونه‌های جدیدی مشابه توزیع داده‌های واقعی تولید کنند؛ این مسیر ابتدا با خانواده‌هایی مانند خودکدگذارهای تغییرپذیر^۱ (VAE) و شبکه‌های مولد تخصصی^۲ (GAN) شکل گرفت و سپس با مدل‌های انتشار احتمالی به سطح تازه‌ای از کیفیت و پایداری رسید [۳۳، ۲۰، ۱۱]. مدل‌های انتشار با فرمول‌بندی تولید تصویر به عنوان وارون‌سازی تدریجی فرآیند نویزدهی، در بسیاری از وظایف تولید

^۱Variational Autoencoders

^۲Generative Adversarial Networks

تصویر کیفیت و تنوع بالایی نشان داده‌اند و در مقایسه با GAN‌ها از پایداری آموزشی مناسب‌تری برخوردارند [۶، ۱۳].

ترکیب مدل‌های انتشار با معماری‌های مبدل، به‌ویژه مبدل بینایی^۳ (ViT)، مسیر شکل‌گیری مدل‌های مولد مقیاس‌پذیر را تقویت کرده است [۴۶، ۱۶]. معماری‌هایی مانند DiT با استفاده از بلوک‌های مبدل و سازوکارهایی مانند adaLN-Zero برای شرط‌گذاری زمانی و کلاسی، نشان داده‌اند که افزایش ظرفیت و محاسبات می‌تواند کیفیت تولید تصویر را بهبود دهد [۴۶]. با این حال، استفاده از این مدل‌های بزرگ در دامنه‌های خاص، تنظیم دقیق کامل همه پارامترها (Full Fine-Tuning)، حافظه گرافیکی زیاد، زمان آموزش طولانی و ذخیره نسخه‌های متعدد از مدل را به مسئله‌ای پرهزینه تبدیل می‌کند [۵۴، ۶۸].

در پاسخ به این چالش، روش‌های تنظیم دقیق پارامتر-کارا^۴ توسعه یافته‌اند تا تنها بخش کوچکی از پارامترها برای سازگار کردن مدل با وظیفه جدید آموزش داده شود [۵۴، ۲۹]. با این حال، اگر تغییرات فقط در همان وضوح توکنی فشرده بدنه اصلی اعمال شوند، ممکن است بازسازی جزئیات مکانی و مؤلفه‌های فرکانس بالا محدود بماند. این مسئله انگیزه‌ای برای طراحی شاخه‌هایی است که بتوانند با وضوح مکانی بالاتر ویژگی‌های محلی را استخراج کنند و در عین حال بدنه اصلی مدل را ثابت نگه دارند [۵، ۶۰].

یکی از راهکارهای مناسب برای این هدف، تفکیک وظایف «درک معنایی» و «حفظ جزئیات» در قالب معماری دوجریانی (Dual-Stream Architecture) است [۵، ۶۰]. در این دیدگاه، جریان اصلی می‌تواند ساختار کلی و مفاهیم سطح بالا را حفظ کند، در حالی که جریان موازی کم‌هزینه روی جزئیات ریزدانه و ویژگی‌های فرکانس بالا تمرکز دارد [۶۰]. چالش اصلی چنین طراحی‌ای، همگام‌سازی و ادغام کنترل‌شده اطلاعات جریان فرعی با بدنه اصلی است تا فرآیند تولید تصویر از نظر معنایی و مکانی منسجم باقی بماند [۱، ۵].

³Vision Transformer

⁴Parameter-Efficient Fine-Tuning

ترکیب هدفمند دو جریان نیازمند راهبردهایی فراتر از جمع ساده ویژگی‌هاست، زیرا خروجی شاخه وضوح بالا باید پیش از ادغام با جریان اصلی از نظر طول توالی و فضای ویژگی هم‌راستا شود [۱، ۵]. استفاده از توجه متقاطع یا توکن‌های خلاصه‌ساز، از جمله توکن کلاس محلی، می‌تواند نقش یک واسط فشرده میان اطلاعات محلی و بازنمایی سراسری را ایفا کند [۵، ۱۶]. چنین سازوکاری به مدل اجازه می‌دهد در عین حفظ دانش کلی بدنه اصلی، اطلاعات ریزدانه و مکانی را نیز به صورت کنترل‌شده وارد فرآیند تولید کند [۱، ۴۶].

علاوه بر ارتقای کیفیت بصری، منجمد نگه داشتن بخش اعظم شبکه و آموزش تنها شاخه کمکی می‌تواند فشار حافظه، تعداد پارامترهای آموزش‌پذیر و هزینه ذخیره مدل را کاهش دهد [۲۹، ۵۴]. این ویژگی برای کاربردهایی که نیازمند تنظیم دقیق سریع، شخصی‌سازی یا سازگاری با دامنه جدید هستند اهمیت ویژه‌ای دارد، زیرا امکان بهره‌گیری از Large Diffusion Models را بدون آموزش مجدد کامل فراهم می‌کند [۵۲، ۶۶، ۲۱]. بنابراین، طراحی یک مسیر کمکی سبک در کنار بدنه اصلی منجمد، از نظر محاسباتی و کاربردی با جهت‌گیری پژوهش‌های اخیر در مدل‌های مولد همسو است [۴۶، ۵۴].

در نهایت، تمرکز اصلی این پایان‌نامه بر اعمال تغییرات معماری هدفمند در مدل DiT است تا تنظیم دقیق پارامتر-کارا با حفظ جزئیات محلی ممکن شود [۴۶، ۵۴]. بر اساس معماری نهایی پیاده‌سازی‌شده، یک شاخه موازی تحت عنوان x_2 به شبکه افزوده می‌شود که ویژگی‌های مکمل را با وضوح مکانی بالاتر استخراج می‌کند و سپس از طریق توکن‌های کلاس محلی با جریان اصلی هم‌راستا و ادغام می‌شود [۲۳، ۵]. ارزیابی این پژوهش روی تولید شرطی ImageNet-1K نشان می‌دهد که DuoDiT-200 با آموزش 17.95M پارامتر از مجموع 690.39M پارامتر، به $FID=2.219$ ، $KID=0.0014$ و $LPIPS-Mean=0.7162$ می‌رسد. این طراحی با منجمد نگه داشتن بدنه اصلی (Frozen Backbone)، امکان بهره‌گیری از دانش پیش‌آموزش‌دیده را حفظ می‌کند و هم‌زمان مسیر سبک‌تری برای سازگاری با داده‌ها یا کلاس‌های هدف فراهم می‌آورد [۴۴، ۴۶].

فصل ۱

مفاهیم اولیه

تولید تصویر^۱ یکی از مفاهیم پایه‌ای مدل‌سازی مولد است و به یادگیری توزیع داده‌های تصویری و نمونه‌برداری از آن برای ساخت تصاویر جدید، طبیعی و معنادار اشاره دارد؛ به گونه‌ای که تصویر تولیدشده از نظر ساختار، محتوا و جزئیات بصری به نمونه‌های واقعی شباهت داشته باشد [۶، ۱۱]. این مسئله در حالت پایه معمولاً ماهیتی بی‌ناظر یا خودنظارتی دارد، زیرا هدف مدل، یادگیری الگوهای پنهان موجود در مجموعه‌ای از تصاویر بدون نیاز به برچسب‌گذاری کامل برای هر ویژگی بصری است؛ هرچند در بسیاری از کاربردها می‌توان با افزودن شرط‌هایی مانند برچسب کلاس، متن یا تصویر راهنما، فرآیند تولید را کنترل کرد [۱۳، ۴۹]. بر همین اساس، تعریف تولید تصویر نیز بخشی از مفاهیم اولیه این فصل است و در ادامه، برای فراهم شدن زمینه معرفی معماری پیشنهادی، معماری‌های بنیادی یادگیری عمیق، مدل‌های مولد شامل خودکدگذارهای تغییرپذیر، شبکه‌های مولد تخصصی و مدل‌های انتشار، مبدل‌ها، مبدل‌های بینایی، مجموعه داده مورد استفاده و معیارهای ارزیابی مرور می‌شوند [۳۳، ۲۰، ۶].

¹Image Generation

۱.۱ شبکه‌های عصبی پیچشی (CNN)

شبکه‌های عصبی پیچشی^۲ یکی از مهم‌ترین معماری‌های یادگیری عمیق هستند که به‌طور خاص برای پردازش داده‌های دارای ساختار شبکه‌ای، مانند تصاویر، طراحی شده‌اند. ایده اصلی این شبکه‌ها الهام‌گرفته از سیستم بینایی بیولوژیکی است و بر پایه عملیات ریاضی «پیچش» بنا شده است [۳۴]. در این شبکه‌ها، به جای اتصال تمام نورون‌ها به هم (مانند شبکه‌های تمام‌متصل)، از فیلترها (کرنل‌ها) برای استخراج ویژگی‌های محلی استفاده می‌شود. این فیلترها روی تصویر ورودی لغزیده و ویژگی‌های مختلفی مانند لبه‌ها، بافت‌ها و الگوهای پیچیده‌تر را در لایه‌های عمیق‌تر شناسایی می‌کنند. دو مفهوم کلیدی در این معماری‌ها وجود دارد. نخست، «اشتراک وزن»^۳ که در آن تمام نورون‌های یک نقشه ویژگی^۴ از فیلتر یکسانی استفاده می‌کنند و باعث کاهش چشمگیر تعداد پارامترها و ایجاد خاصیت تغییرناپذیری نسبت به انتقال^۵ می‌شود. دوم، استفاده از «لایه‌های تجمیع»^۶ است که ابعاد مکانی ویژگی‌ها را کاهش می‌دهند^۷ تا هم محاسبات سبک‌تر شود و هم شبکه نسبت به تغییرات جزئی مکان ویژگی‌ها مقاوم‌تر گردد [۳۴].

۲.۱ خودکدگذارهای تغییرپذیر (VAE)

خودکدگذارهای تغییرپذیر (VAE) دسته‌ای از مدل‌های مولد احتمالی هستند که برخلاف خودکدگذارهای معمولی که ورودی را به یک نقطه ثابت در فضای نهان نگاشت می‌کنند، آن را به یک توزیع احتمالی (معمولاً توزیع نرمال) نگاشت می‌نمایند [۳۳]. معماری VAE شامل دو بخش اصلی است. بخش اول، «رمزگذار»^۸ است که یک شبکه عصبی احتمالی $q_\phi(z|x)$ بوده و پارامترهای توزیع نهان (میانگین

^۲Convolutional Neural Networks

^۳Weight Sharing

^۴Feature Map

^۵Translation Invariance

^۶Pooling Layer

^۷Max Pooling

^۸Encoder

μ و واریانس (σ^2) را برای ورودی x پیش‌بینی می‌کند. بخش دوم، «رمزگشا»^۹ با توزیع $p_\theta(x|z)$ است که تلاش می‌کند داده ورودی را با نمونه‌برداری از فضای نهان z بازسازی کند. هدف آموزش در این مدل‌ها، بیشینه‌سازی کران پایین شواهد^{۱۰} است که شامل دو مؤلفه اصلی می‌شود؛ خطای بازسازی که باعث شباهت خروجی به ورودی شده، و واگرایی کولبک-لایبلر^{۱۱} که تضمین می‌کند توزیع فضای نهان به توزیع پیشین (معمولاً نرمال استاندارد) نزدیک بماند تا امکان تولید نمونه‌های جدید فراهم گردد [۳۳].

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x)||p(z)) \quad (۱.۲.۱)$$

۳.۱ شبکه‌های مولد تخصصی (GAN)

شبکه‌های مولد تخصصی (GAN) که توسط گودفلو و همکاران معرفی شدند، رویکردی متفاوت برای تولید داده دارند که مبتنی بر تئوری بازی‌هاست [۲۰]. این مدل از دو شبکه عصبی تشکیل شده است که در یک بازی مجموع‌صفر با هم رقابت می‌کنند. شبکه اول، «مولد»^{۱۲} نام دارد و سعی می‌کند داده‌های مصنوعی تولید کند که تا حد ممکن شبیه به داده‌های واقعی باشند تا رقیب خود را فریب دهد. شبکه دوم، «متمایزگر»^{۱۳} است که وظیفه دارد تشخیص دهد که داده ورودی، واقعی (از مجموعه داده) است یا جعلی (تولید شده توسط G). تابع هدف این بازی به صورت زیر تعریف می‌شود:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)}[\log D(x)] + \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z)))] \quad (۱.۳.۲)$$

^۹Decoder

^{۱۰}Evidence Lower Bound - ELBO

^{۱۱}KL Divergence

^{۱۲}Generator - G

^{۱۳}Discriminator - D


در حالی که GANها قادر به تولید تصاویر با کیفیت بسیار بالا هستند، آموزش آنها اغلب ناپایدار بوده و با مشکلاتی نظیر فروپاشی مود^{۱۴} مواجه می‌شوند [۲۰، ۱۳].

۴.۱ مدل‌های انتشار (Diffusion Models)

مدل‌های انتشار به عنوان یکی از پیشرفته‌ترین چارچوب‌های تولید داده در سال‌های اخیر شناخته می‌شوند و اساس کار آنها بر شبیه‌سازی یک فرایند تبدیل تدریجی نویز تصادفی به داده منسجم مبتنی است [۵۳].

¹⁴Mode Collapse

۱.۴.۱ فرآیند انتشار و معادلات



شکل ۱.۴.۱: شمای کلی فرآیند انتشار: مسیر رو به جلو (افزودن نویز) و مسیر معکوس (حذف نویز).

همان‌طور که در شکل ۱.۴.۱ نشان داده شده است، این سازوکار شامل دو مسیر مجزا است. نخست، «مسیر انتشار رو به جلو»^{۱۵} که طی آن نویز گاوسی به صورت تدریجی در T مرحله به داده افزوده می‌شود تا جایی که داده عملاً به نویز خالص تبدیل شود. این فرآیند معمولاً به صورت یک زنجیره مارکوف با توزیع شرطی گاوسی $q(x_t|x_{t-1})$ مدل می‌شود. دوم، «مسیر انتشار معکوس»^{۱۶} است که

¹⁵Forward Process

¹⁶Reverse Process

هدف اصلی مدل محسوب می‌شود و باید فرآیند افزوده شدن نویز را معکوس کند، یعنی $p_{\theta}(x_{t-1}|x_t)$. در این مرحله، یک شبکه عصبی (مانند U-Net) برای پیش‌بینی نویز اضافه شده در هر گام زمانی آموزش می‌بیند [۶، ۱۱].

فرمول کلی فرآیند تصادفی پیوسته در مدل‌های انتشار را می‌توان با معادله دیفرانسیل تصادفی^{۱۷} توصیف کرد:

$$dx = f(t, x) dt + \sigma(t) dw$$

که در آن $f(t, x)$ ضریب رانش و $\sigma(t)$ ضریب نفوذ است. برای تولید نمونه، مدل باید تابع نمره^{۱۸} یا گرادیان لگاریتم چگالی داده را تخمین بزند [۱۱].

در کنار مدل‌های پایه احتمالی^{۱۹}، نسخه‌های توسعه‌یافته‌ای نظیر DDIM برای نمونه‌برداری قطعی و سریع‌تر، و مدل‌های انتشار در فضای پنهان^{۲۰} برای کاهش بار محاسباتی معرفی شده‌اند [۲۳].

۵.۱ شبکه‌های عصبی بازگشتی (RNN)

شبکه‌های عصبی بازگشتی^{۲۱} برای پردازش داده‌های متوالی (مانند متن، صوت یا سری‌های زمانی) توسعه یافته‌اند. ویژگی متمایز RNN وجود حلقه‌های بازخوردی است که به شبکه اجازه می‌دهد اطلاعات مراحل قبلی زمان $(t - 1)$ را در قالب یک «حالت پنهان»^{۲۲} حفظ کرده و در پردازش ورودی فعلی (x_t) استفاده کند [۵۰]. معادله به‌روزرسانی حالت پنهان h_t به صورت کلی برابر است با:

$$h_t = f(W_h h_{t-1} + W_x x_t + b) \quad (۱.۵.۳)$$

^{۱۷}SDE

^{۱۸}Score Function


^{۱۹}DDPM

^{۲۰}Latent Diffusion Models

^{۲۱}Recurrent Neural Networks

^{۲۲}Hidden State

اگرچه RNN ها، مطابق ساختار نمایش داده شده در شکل ۱.۵.۲، برای داده های متوالی مناسب هستند، اما در یادگیری وابستگی های طولانی مدت دچار مشکل «محو شدن گرادیان»^{۲۳} می شوند که مانع از انتقال موثر اطلاعات در طول توالی های طولانی می گردد [۲۸، ۵۹].



شکل ۱.۵.۲: معماری شبکه عصبی بازگشتی (RNN) و نحوه باز شدن آن در طول زمان.

برای حل مشکل حافظه کوتاه مدت در RNN های ساده، معماری LSTM^{۲۴} معرفی شد که ساختار داخلی آن در شکل ۱.۵.۳ آمده است. این معماری با معرفی یک «سلول حافظه»^{۲۵} و مکانیزم های کنترلی به نام «دروازه»^{۲۶}، جریان اطلاعات را دقیق تر مدیریت می کند. یک واحد LSTM استاندارد شامل سه دروازه اصلی است. «دروازه فراموشی»^{۲۷} تصمیم می گیرد چه اطلاعاتی از حافظه دور ریخته شود. سپس «دروازه ورودی»^{۲۸} مشخص می کند چه اطلاعات جدیدی باید در حافظه ذخیره شود و در نهایت «دروازه خروجی»^{۲۹} تعیین می کند چه بخشی از حافظه به عنوان خروجی لحظه ای ارسال گردد. این ساختار به LSTM اجازه می دهد تا وابستگی های زمانی طولانی تری را نسبت به RNN معمولی مدل کند [۲۸].

²³Vanishing Gradient

²⁴Long Short-Term Memory


²⁵Cell State

²⁶Gate

²⁷Forget Gate

²⁸Input Gate

²⁹Output Gate




شکل ۱.۵.۳: ساختار داخلی یک واحد LSTM شامل دروازه‌های فراموشی، ورودی و خروجی.

۶.۱ مدل‌ها^{۳۰}

معماری مدل که ساختار کلی آن در شکل ۱.۶.۴ نمایش داده شده است، اولین بار در مقاله «توجه تمام چیزی است که نیاز دارید» معرفی شد و پارادایم پردازش توالی‌ها را تغییر داد [۵۹]. برخلاف RNN‌ها که داده‌ها را به صورت ترتیبی پردازش می‌کنند، مدل‌ها با استفاده از مکانیزم «توجه»^{۳۱} امکان پردازش موازی کل توالی را فراهم می‌کنند.

³⁰ Transformers

³¹ Attention



شکل ۱.۶.۴: ساختار کلی معماری مبدل شامل رمزگذار و رمزگشا.

۱.۶.۱ مکانیزم توجه^{۳۲}

مؤلفه مرکزی مبدل، مکانیزم خود توجه^{۳۳} است. فرض کنید توالی ورودی به صورت ماتریس $X \in \mathbb{R}^{n \times d}$ نمایش داده شود که در آن n طول توالی و d بعد ویژگی‌ها است. در این مکانیزم، برای هر توکن سه بردار پرسش (Q)، کلید (K) و مقدار (V) از طریق ضرب در ماتریس‌های وزن قابل یادگیری $W^Q, W^K, W^V \in \mathbb{R}^{d \times d_k}$ تولید می‌شوند. خروجی توجه برابر است با مجموع وزن‌دار مقادیر، که وزن‌ها بر اساس شباهت پرسش و کلیدها تعیین می‌شوند [۵۹]:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (1.6.4)$$

که در آن d_k بعد بردار کلید است. برای افزایش ظرفیت مدل در یادگیری جنبه‌های مختلف توالی، از توجه چندسره^{۳۴} استفاده می‌شود که در آن h عملیات توجه به صورت موازی انجام شده و نتایج آن‌ها با هم تجمیع می‌گردند [۵۹]:

$$\text{MHA}(X) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h) W^O \quad (1.6.5)$$

$$\text{head}_i = \text{Attention}(XW_i^Q, XW_i^K, XW_i^V) \quad (1.6.6)$$

در اینجا $W^O \in \mathbb{R}^{hd_v \times d}$ ماتریس نگاشت خروجی است و هر سر توجه ماتریس‌های وزن مخصوص به خود را دارد.

۲.۶.۱ لایه رمزگذار و شبکه پیش‌خور

پس از مکانیزم توجه، یک شبکه پیش‌خور واحد^{۳۵} به صورت مجزا بر روی هر توکن اعمال می‌شود. این شبکه شامل دو تبدیل خطی و یک فعال‌ساز غیرخطی (مانند ReLU یا GELU) است [۵۹]:

$$\text{FFN}(x) = \text{GELU}(xW_1 + b_1)W_2 + b_2 \quad (1.6.7)$$

³²Attention Mechanism

³³Self-Attention

³⁴Multi-Head Attention - MHA

³⁵Feed-Forward Network

که در آن $\mathbf{W}_1 \in \mathbb{R}^{d \times d_{ff}}$ و $\mathbf{W}_2 \in \mathbb{R}^{d_{ff} \times d}$ پارامترهای مدل هستند و d_{ff} معمولاً چهار برابر بعد اصلی در نظر گرفته می‌شود. ساختار کلی یک لایه رمزگذار مبدل با استفاده از نرمال‌سازی لایه^{۳۶} و اتصالات باقی‌مانده پیاده‌سازی می‌شود. در نسخه استاندارد (Post-LN)، نرمال‌سازی پس از افزودن باقی‌مانده اعمال می‌گردد:

$$\mathbf{X}' = \text{LayerNorm}(\mathbf{X} + \text{MHA}(\mathbf{X})) \quad (۱.۶.۸)$$

$$\mathbf{X}'' = \text{LayerNorm}(\mathbf{X}' + \text{FFN}(\mathbf{X}')) \quad (۱.۶.۹)$$

در حالی که در نسخه‌های مدرن‌تر (مانند Pre-LN)، نرمال‌سازی پیش از ورود به هر زیرلایه انجام می‌شود تا پایداری آموزش افزایش یابد:

$$\mathbf{X}' = \mathbf{X} + \text{MHA}(\text{LayerNorm}(\mathbf{X})) \quad (۱.۶.۱۰)$$

$$\mathbf{X}'' = \mathbf{X}' + \text{FFN}(\text{LayerNorm}(\mathbf{X}')) \quad (۱.۶.۱۱)$$

فرآیند نرمال‌سازی لایه برای یک بردار ویژگی $\mathbf{x}$ به‌صورت زیر تعریف می‌شود:

$$\text{LayerNorm}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \quad (۱.۶.۱۲)$$

که در آن μ و σ^2 میانگین و واریانس المان‌ها، γ و β پارامترهای قابل یادگیری و ϵ مقدار کوچکی برای پایداری عددی است [۵۹].

۳.۶.۱ تعبیه موقعیت

از آنجا که معماری مبدل برخلاف شبکه‌های بازگشتی فاقد ساختار ترتیبی ذاتی است، برای حفظ اطلاعات ترتیب توکن‌ها از تعبیه موقعیت^{۳۷} استفاده می‌شود. یکی از روش‌های رایج، استفاده از

^{۳۶}Layer Normalization

^{۳۷}Positional Encoding

توابع سینوسی و کسینوسی با فرکانس‌های متفاوت برای هر بعد است:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad (1.6.13)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (1.6.14)$$

در اینجا pos نشان‌دهنده موقعیت توکن در توالی و i شاخص بعد ویژگی است. این بازنمایی به مدل اجازه می‌دهد تا روابط نسبی بین توکن‌ها را به صورت مؤثر مدل کند [۵۹].

۷.۱ مبدل‌های بینایی (ViT)

مبدل‌های بینایی، موفقیت معماری مبدل را از حوزه متن به بینایی ماشین منتقل کردند [۱۶]. در این معماری، ابتدا یک تصویر ورودی $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ که در آن H و W به ترتیب ارتفاع و عرض تصویر و C تعداد کانال‌های رنگی است، به N تکه غیرهم‌پوشان با اندازه $P \times P$ تقسیم می‌شود. تعداد تکه‌ها از رابطه $N = HW/P^2$ به دست می‌آید. هر تکه تسطیح شده و به صورت خطی به فضایی با بعد D نگاشت می‌شود:

$$\mathbf{z}_0^i = \mathbf{E}\mathbf{x}_p^i, \quad i = 1, 2, \dots, N \quad (1.7.15)$$

که در آن $\mathbf{x}_p^i \in \mathbb{R}^{P^2 \cdot C}$ بردار تسطیح شده تکه i -ام و $\mathbf{E} \in \mathbb{R}^{D \times (P^2 \cdot C)}$ ماتریس تصویر برداری خطی است. برای حفظ اطلاعات مکانی، یک توکن کلاسی قابل یادگیری $\mathbf{z}_0^0$ و بردارهای تعبیه موقعیت $\mathbf{E}_{pos}$ به توالی اضافه می‌شوند [۱۶]:

$$\mathbf{z}_0 = [\mathbf{z}_0^0; \mathbf{E}\mathbf{x}_p^1; \mathbf{E}\mathbf{x}_p^2; \dots; \mathbf{E}\mathbf{x}_p^N] + \mathbf{E}_{pos} \quad (1.7.16)$$

در اینجا $\mathbf{E}_{pos} \in \mathbb{R}^{(N+1) \times D}$ ماتریس تعبیه موقعیت است که در طول فرآیند آموزش یاد گرفته می‌شود. توالی حاصل سپس توسط L لایه رمزگذار مبدل پردازش می‌شود. هر لایه ℓ شامل دو بخش

اصلی است؛ ابتدا مکانیزم خود توجه چندسره^{۳۸} که با نرمال سازی لایه و اتصال باقی مانده^{۳۹} همراه است:

$$\mathbf{z}'_{\ell} = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1} \quad (10.7.17)$$

در این رابطه، خروجی MSA همان صورت چندسره رابطه های ۱.۶.۵ و ۱.۶.۶ است؛ با این تفاوت که ورودی توالی از $\mathbf{X}$ به توکن های تصویری $\mathbf{z}$ تغییر می کند. هر سر توجه نیز همچنان بر پایه توجه ضرب داخلی مقیاس شده در رابطه ۱.۶.۴ محاسبه می شود [۱۶، ۵۹]. پس از آن، یک شبکه پیش خور^{۴۰} اعمال می شود که شامل دو لایه خطی و یک تابع فعال ساز غیرخطی GELU است:

$$\mathbf{z}_{\ell} = \text{MLP}(\text{LN}(\mathbf{z}'_{\ell})) + \mathbf{z}'_{\ell} \quad (10.7.18)$$

تابع MLP از نظر ساختار همان شبکه پیش خور رابطه ۱.۶.۷ است و به صورت مستقل روی هر توکن تصویری اعمال می شود [۱۶]. در نهایت، برای انجام وظیفه طبقه بندی، از بازنمایی توکن کلاسی در خروجی آخرین لایه (L -ام) استفاده می شود. پس از اعمال یک نرمال سازی نهایی، توزیع احتمالی کلاس ها توسط تابع سافت مکس به دست می آید [۱۶]:

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0) \quad (10.7.19)$$


$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}_{head}\mathbf{y} + \mathbf{b}_{head}) \quad (10.7.20)$$

پارامترهای کلیدی در این معماری، که نمای کلی آن و نحوه کار آن در شکل ۱.۷.۵ آمده است [۱۶].

³⁸Multi-Head Self-Attention - MSA

³⁹Residual Connection

⁴⁰Feed-Forward Network - MLP



شکل ۱.۷.۵: معماری مبدل بینایی (ViT) شامل تقسیم تصویر به تکه‌ها، تعبیه خطی و رمزگذار مبدل.

۸.۱ تنظیم دقیق پارامتر-کارا (PEFT)

با رشد نمایی ابعاد مدل‌های زبانی و تصویری، تنظیم دقیق کامل^{۴۱} تمام پارامترها برای هر کاربرد جدید بسیار پرهزینه و گاهی غیرممکن شده است. روش‌های تنظیم دقیق پارامتر-کارا^{۴۲} راهکاری برای این چالش هستند. هدف PEFT دستیابی به عملکردی مشابه تنظیم دقیق کامل، اما با تغییر تعداد بسیار اندکی از پارامترهاست. در ادامه دو مورد از مهم‌ترین این روش‌ها، یعنی تنظیم پیشوند و تنظیم جانبی تشریح می‌شوند.

۱.۸.۱ تنظیم پیشوند (Prefix Tuning)

روش تنظیم پیشوند، الهام‌گرفته از مهندسی پرامپت است اما به جای استفاده از توکن‌های گسسته، از بردارهای پیوسته قابل یادگیری استفاده می‌کند. در این روش، یک دنباله از بردارهای پیوسته^{۴۳} به نام «پیشوند» (P) به ابتدای ورودی مدل اضافه می‌شود. اگر x ورودی و y خروجی باشد، مدل زبانی

^{۴۱}Full Fine-Tuning

^{۴۲}Parameter-Efficient Fine-Tuning

^{۴۳}Continuous Vectors

با پارامترهای ϕ احتمال شرطی $p_\phi(y|x)$ را مدل سازی می کند. در تنظیم پیشوند، پارامترهای اصلی مدل ϕ ثابت نگه داشته می شوند و تنها پارامترهای پیشوند θ_P آموزش می بینند. برای یک توکن در گام i ، وضعیت پنهان h_i به صورت زیر محاسبه می شود:

$$h_i = \begin{cases} P[i], & \text{if } i < \text{len}(P) \\ \text{LM}(z_i, h_{<i}, \phi), & \text{otherwise} \end{cases} \quad (1.8.21)$$

که در آن P ماتریس پارامترهای پیشوند است. این مکانیزم به مدل اجازه می دهد تا بدون تغییر وزن های اصلی، با زمینه^{۴۴} جدیدی که توسط پیشوند ایجاد شده، خود را با وظیفه جدید وفق دهد.

۲.۸.۱ تنظیم جانبی (Side-Tuning)

روش تنظیم جانبی یکی دیگر از رویکردهای کارآمد است که در آن به جای تغییر وزن های اصلی مدل، یک شاخه جانبی کوچک و سبک به موازات مدل اصلی اضافه می شود. در این روش، مدل اصلی (که معمولاً بسیار بزرگ است) به صورت منجمد باقی می ماند و تنها پارامترهای شاخه جانبی آموزش می بینند. خروجی های این شاخه با خروجی های مدل اصلی ادغام می شوند تا رفتار مدل برای وظیفه جدید تطبیق یابد. این روش مزیت مهمی دارد، زیرا دانش پیش آموزش دیده مدل اصلی را تا حد زیادی حفظ می کند و از پدیده «فراموشی فاجعه بار» جلوگیری می کند. همچنین به دلیل سبک بودن شاخه جانبی، هزینه محاسباتی آموزش کاهش می یابد [۵۴، ۶۸].

۹.۱ مجموعه داده ImageNet

مجموعه داده ImageNet یکی از بزرگ ترین و تأثیرگذارترین منابع داده در تاریخ بینایی ماشین است که نقشی محوری در پیشرفت های اخیر یادگیری عمیق ایفا کرده است [۱۲]. این پروژه با هدف فراهم کردن یک پایگاه داده تصویری جامع و سازمان یافته بر اساس سلسله مراتب معنایی WordNet راه اندازی شد. در این ساختار، مفاهیم به صورت دسته هایی از کلمات هم معنی^{۴۵} گروه بندی شده اند

⁴⁴Context

⁴⁵Synsets

و برای هر مفهوم، صدها یا هزاران تصویر جمع‌آوری و توسط انسان برچسب‌گذاری شده است. اهمیت این مجموعه‌داده فراتر از حجم آن است؛ تنوع قابل توجه تصاویر از زوایای دید متفاوت، شرایط نوری گوناگون و انسدادهای جزئی باعث شده تا مدل‌هایی که روی آن آموزش می‌بینند، بازنمایی‌های بصری بسیار غنی و قابل تعمیمی را یاد بگیرند که در بسیاری از وظایف پایین‌دستی^{۴۶} کاربرد دارد.

از نظر خصوصیات آماری، نسخه کامل ImageNet شامل بیش از ۱۴ میلیون تصویر برچسب‌خورده است که بیش از ۲۱ هزار دسته هم‌معنی مختلف را پوشش می‌دهند. با این حال، نسخه‌ای که بیشتر در تحقیقات و رقابت‌های علمی مورد ارجاع قرار می‌گیرد، زیرمجموعه‌ای است که برای چالش بازنمایی بصری در مقیاس بزرگ^{۴۷} استفاده شده و به ImageNet-1K مشهور است. این نسخه شامل حدود 1.28 میلیون تصویر آموزشی و ۵۰ هزار تصویر اعتبارسنجی در ۱۰۰۰ کلاس متنوع است که اشیاء روزمره، حیوانات، وسایل نقلیه و مناظر طبیعی را در بر می‌گیرد. علاوه بر این، نسخه بزرگ‌تر ImageNet-21K که شامل تمام دسته‌ها است، امروزه به طور فزاینده‌ای برای پیش‌آموزش مدل‌های عظیم مانند Vision Transformers استفاده می‌شود، زیرا حجم داده‌های بیشتر در آن به بهبود کارایی مدل در مقیاس‌های بزرگ کمک می‌کند. خلاصه‌ای از مشخصات آماری نسخه ImageNet-1K در جدول ۱.۹.۱ ارائه شده است.

جدول ۱.۹.۱: اطلاعات آماری مجموعه‌داده ImageNet

ویژگی	مقدار
تعداد کلاس‌ها (ImageNet-1K)	۱۰۰۰
تصاویر آموزشی	۱,۲۸۱,۱۶۷
تصاویر اعتبارسنجی	۵۰,۰۰۰
تصاویر آزمون	۱۰۰,۰۰۰
سال انتشار	۲۰۰۹

⁴⁶Downstream Tasks

⁴⁷ILSVRC

۱۰.۱ معیارهای ارزیابی

برای مقایسه کمی مدل‌ها از سه معیار استاندارد استفاده شده است: FID برای فاصله توزیعی، KID برای برآورد مبتنی بر MMD و LPIPS-Mean برای شباهت ادراکی مبتنی بر ویژگی‌های عمیق [۲۴، ۳، ۷۴]. در ارزیابی اصلی، FID با پروتکل FID-50K روی ۵۰,۰۰۰ نمونه تولیدشده از همه کلاس‌های ImageNet-1K گزارش می‌شود. معیار KID نیز مکمل FID است، زیرا به صورت برآورد بدون سوگیری فاصله توزیعی عمل می‌کند. برای سنجش کیفیت ادراکی، LPIPS-Mean میانگین فاصله ادراکی همه زوج‌های تصویر تولیدی و واقعی متناظر در هر کلاس را اندازه می‌گیرد و سپس روی کلاس‌ها میانگین‌گیری می‌شود [۴۶، ۱۲].

معیار نخست، فاصله فریشه اینسپشن^{۴۸} (FID) است. در این معیار، تصاویر واقعی و تولیدشده ابتدا با شبکه Inception به فضای ویژگی نگاشت می‌شوند و سپس هر توزیع ویژگی با یک توزیع گاوسی تقریب زده می‌شود. اگر میانگین و کوواریانس ویژگی‌های تصاویر واقعی به ترتیب μ_r و Σ_r ، و میانگین و کوواریانس ویژگی‌های تصاویر تولیدشده μ_g و Σ_g باشد، مقدار FID به صورت زیر محاسبه می‌شود [۲۴]:

$$FID = \|\mu_r - \mu_g\|_2^2 + \text{Tr} \left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}} \right). \quad (10.10.22)$$

در رابطه ۱۰.۱۰.۲۲، عبارت اول فاصله میانگین‌های دو توزیع و عبارت دوم تفاوت ساختار کوواریانس آن‌ها را اندازه‌گیری می‌کند. مقدار کمتر FID نشان می‌دهد توزیع ویژگی‌های تصاویر تولیدشده به توزیع تصاویر واقعی نزدیک‌تر است [۲۴].

معیار دوم، فاصله هسته‌ای اینسپشن^{۴۹} (KID) است که بر پایه بیشینه میانگین اختلاف^{۵۰} تعریف می‌گردد. اگر $X = \{x_i\}_{i=1}^m$ ویژگی‌های تصاویر واقعی و $Y = \{y_j\}_{j=1}^n$ ویژگی‌های تصاویر تولیدشده

⁴⁸Fréchet Inception Distance

⁴⁹Kernel Inception Distance

⁵⁰Maximum Mean Discrepancy - MMD

باشند، برآورد بدون سوگیری MMD به صورت زیر نوشته می شود [۳]:

$$(۱.۱۰.۲۳)$$

$$\text{KID} = \frac{1}{m(m-1)} \sum_{i \neq j} k(x_i, x_j) + \frac{1}{n(n-1)} \sum_{i \neq j} k(y_i, y_j) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j).$$

در این رابطه، $k(\cdot, \cdot)$ معمولاً یک هسته چندجمله‌ای روی ویژگی‌های اینسپشن است، مانند $k(x, y) = (\frac{1}{d}x^\top y + 1)^3$ که در آن d بعد بردار ویژگی است. مقدار کمتر KID نشان‌دهنده شباهت بیشتر دو مجموعه تصویر است و به دلیل برآورد بدون سوگیری، در مجموعه‌های نمونه کوچک نیز قابل استفاده است [۳].

معیار سوم، شباهت ادراکی یادگرفته‌شده قطعه‌های تصویر^{۵۱} (LPIPS) است که شباهت ادراکی دو تصویر را با استفاده از فاصله ویژگی‌های میانی یک شبکه عمیق محاسبه می‌کند. اگر $\hat{y}_{hw}^l$ و $\hat{y}_{hw}^n$ ویژگی‌های نرمال‌شده دو تصویر در لایه l و مکان مکانی (h, w) باشند، مقدار LPIPS به صورت زیر تعریف می‌شود [۷۴]:

$$\text{LPIPS}(x, x') = \sum_l \frac{1}{H_l W_l} \sum_{h=1}^{H_l} \sum_{w=1}^{W_l} \|w_l \odot (\hat{y}_{hw}^l - \hat{y}_{hw}^n)\|_2^2. \quad (۱.۱۰.۲۴)$$

در رابطه ۱.۱۰.۲۴، w_l وزن‌های یادگرفته‌شده برای اهمیت کانال‌های لایه l ، و H_l و W_l ابعاد مکانی نقشه ویژگی هستند. برخلاف FID و KID که توزیع کلی مجموعه تصاویر را مقایسه می‌کنند، LPIPS روی شباهت ادراکی زوج‌تصویرها تمرکز دارد و به جزئیات محلی، بافت و ساختارهای بصری حساس‌تر است؛ بنابراین مقدار کمتر آن نشان‌دهنده شباهت ادراکی بیشتر است [۷۴].

در این پایان‌نامه، نسخه گزارش‌شده از این معیار با عنوان LPIPS-Mean تعریف می‌شود. اگر G_c مجموعه تصاویر تولیدشده برای کلاس c و R_c مجموعه تصاویر واقعی همان کلاس باشد، مقدار کلاسی این معیار به صورت زیر محاسبه می‌شود:

$$\text{LPIPS-Mean}_c = \frac{1}{|G_c||R_c|} \sum_{g \in G_c} \sum_{r \in R_c} d_{\text{LPIPS}}(g, r). \quad (۱.۱۰.۲۵)$$

⁵¹ Learned Perceptual Image Patch Similarity

در نهایت، میانگین LPIPS-Mean روی کلاس‌های ارزیابی شده گزارش می‌شود. این تعریف با مقایسه همه زوج‌های تولیدی و واقعی، دید دقیق‌تری از فاصله ادراکی میان خروجی مدل و داده واقعی فراهم می‌کند.

فصل ۲

پیشینه پژوهش

در فصل پیش، مفاهیم پایه‌ای مدل‌های مولد، مدل‌های انتشار و مبدل‌های بینایی در سطح مقدماتی معرفی شد. در این فصل، تمرکز از تعریف اولیه به سمت چارچوب‌های پژوهشی و مسیر تکامل مدل‌های انتشار می‌رود؛ به گونه‌ای که ابتدا فرمول‌بندی‌های اصلی این خانواده از مدل‌ها، شامل DDPM، مدل‌های مبتنی بر امتیاز، فرمول‌بندی پیوسته و روش‌های نمونه‌برداری مرور می‌شوند. سپس نشان داده می‌شود که چرا پس از تثبیت این چارچوب‌ها، انتخاب معماری شبکه حذف نویز اهمیت پیدا کرده و چگونه این مسیر به مدل‌های انتشار مبتنی بر مبدل، به‌ویژه DiT، منتهی شده است. در ادامه، روندهای تکمیلی از نظر مقیاس‌پذیری، کنترل‌پذیری و حفظ جزئیات محلی بررسی می‌گردد. سپس معماری‌های جریان دوگانه و روش‌های تجمیع ویژگی مطالعه می‌شوند تا مبنای نظری شاخه وضوح‌بالای پیشنهادی روشن شود. در پایان نیز روش‌های تنظیم دقیق، به‌ویژه رویکردهای پارامتر-کارا، بررسی می‌شوند؛ زیرا معماری پیشنهادی این پژوهش بر ترکیب یک بدنه اصلی منجمد با یک شاخه جانبی آموزش‌پذیر استوار است [۱۱، ۴۶، ۵، ۵۴].

۱.۲ چارچوب‌های اصلی مدل‌های انتشار

توضیح مقدماتی فصل پیش نشان داد که مدل انتشار از دو مسیر نویزدهی و حذف نویز تشکیل می‌شود. در پیشینه پژوهش، این ایده در چند فرمول‌بندی اصلی توسعه یافته است که هر یک زاویه متفاوتی از همان مسئله را برجسته می‌کنند: در DDPM^۱، فرایند تولید به صورت یک زنجیره مارکوف گسسته مدل می‌شود؛ در مدل‌های مبتنی بر امتیاز، هدف یادگیری گرادیان لگاریتم چگالی داده‌های نویزی است؛ و در فرمول‌بندی پیوسته، هر دو نگاه در قالب معادلات دیفرانسیل تصادفی و معادلات دیفرانسیل معمولی قابل بیان می‌شوند [۵۵، ۲۵، ۵۷، ۵۸]. این بخش برای جلوگیری از تکرار فصل اول، بر تفاوت این چارچوب‌ها، روابط ریاضی کلیدی و جایگاه آن‌ها در تعریف نقش شبکه حذف نویز تمرکز دارد.

۱.۱.۲ مدل‌های DDPM

در فرمول‌بندی احتمالاتی، داده واقعی با $x_0 \sim q_{\text{data}}(x)$ نمایش داده می‌شود و یک زمان‌بندی نویز^۲ شامل ضرایب $\{\beta_t\}_{t=1}^T$ مشخص می‌کند که در هر گام چه مقدار نویز گاوسی به داده افزوده شود. اگر $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ و $\alpha_t = 1 - \beta_t$ باشد، فرایند رو به جلو به صورت زیر نوشته می‌شود [۵۵، ۲۵]:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I). \quad (2.1.1)$$

مزیت این تعریف آن است که نمونه نویزی در هر گام را می‌توان مستقیماً از x_0 نیز به دست آورد:

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad (2.1.2)$$

یا به شکل بازپارامتری‌شده:

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (2.1.3)$$

^۱Denoising Diffusion Probabilistic Models

^۲Noise Schedule

بنابراین، آموزش مدل به معنای یادگیری مسیر معکوس از x_t به x_{t-1} است:

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t)). \quad (2.1.4)$$

در DDPM، به جای پیش‌بینی مستقیم x_{t-1} ، شبکه معمولاً نویز افزوده‌شده را تخمین می‌زند. این انتخاب باعث می‌شود تابع هدف عملی به یک خطای میانگین مربعات ساده تبدیل شود [۲۵]:

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_{\theta}(x_t, t, c)\|_2^2], \quad (2.1.5)$$

که در آن c می‌تواند شرطی مانند برجسب کلاس یا متن باشد. همین رابطه در مدل‌های مبتنی بر DiT نیز حفظ می‌شود؛ تفاوت اصلی در آن است که تابع ϵ_{θ} به جای یک شبکه پیچشی، با یک معماری مبدلی پیاده‌سازی می‌شود [۴۶].

۲.۱.۲ مدل‌های مبتنی بر امتیاز

دیدگاه مبتنی بر امتیاز^۳ مسئله را از زاویه دیگری بیان می‌کند. در این رویکرد، مدل به جای تخمین مستقیم چگالی داده، تابع امتیاز توزیع داده‌های نویزی را یاد می‌گیرد [۵۷، ۵۸]:

$$s_{\theta}(x_t, t) \approx \nabla_{x_t} \log q_t(x_t). \quad (2.1.6)$$

تابع امتیاز جهت افزایش احتمال داده را در فضای نمونه نشان می‌دهد؛ به بیان دیگر، مشخص می‌کند یک نمونه نویزی باید در چه جهتی حرکت کند تا به نواحی محتمل‌تر توزیع داده نزدیک شود. ارتباط این دیدگاه با DDPM از رابطه نویز گاوسی روشن می‌شود. اگر $\sigma_t^2 = 1 - \bar{\alpha}_t$ باشد، امتیاز توزیع شرطی نویزی با نویز افزوده‌شده نسبت مستقیم دارد:

$$\nabla_{x_t} \log q(x_t|x_0) = -\frac{\epsilon}{\sigma_t}. \quad (2.1.7)$$

بنابراین، پیش‌بینی نویز در DDPM و تخمین امتیاز در مدل‌های مبتنی بر امتیاز دو بیان نزدیک از یک مسئله هستند. این ارتباط اهمیت زیادی دارد، زیرا نشان می‌دهد روش‌های مختلف مدل‌های

³Score-Based Modeling

انتشار تنها نام‌گذاری‌های جداگانه نیستند، بلکه از نظر ریاضی به یک خانواده مشترک تعلق دارند [۵۸، ۱۱].

۳.۱.۲ مدل‌های انتشار مبتنی بر SDE

برای یکپارچه‌سازی دیدگاه‌های گسسته و مبتنی بر امتیاز، مدل‌های انتشار را می‌توان در زمان پیوسته با معادله دیفرانسیل تصادفی^۴ بیان کرد [۵۸]:

$$dx = f(x, t) dt + g(t) dw, \quad (۲.۱.۸)$$

که در آن $f(x, t)$ جمله رانش، $g(t)$ شدت نویز و w فرایند وینر است. در مسیر رو به جلو، این معادله داده را به تدریج به توزیع ساده‌ای مانند نرمال استاندارد نزدیک می‌کند. مسیر معکوس نیز با استفاده از تابع امتیاز قابل نوشتن است:

$$dx = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)] dt + g(t) d\bar{w}. \quad (۲.۱.۹)$$

این رابطه نشان می‌دهد که اگر مدل بتواند امتیاز $\nabla_x \log p_t(x)$ را تخمین بزند، می‌توان مسیر تولید را از نویز به داده طی کرد. همچنین یک معادله دیفرانسیل معمولی^۵ متناظر، موسوم به Probability Flow ODE، وجود دارد:

$$\frac{dx}{dt} = f(x, t) - \frac{1}{2} g(t)^2 \nabla_x \log p_t(x). \quad (۲.۱.۱۰)$$

این نگاه پیوسته برای طراحی نمونه‌بردارهای سریع‌تر و تحلیل ارتباط میان خانواده‌های مختلف مدل‌های انتشار اهمیت دارد؛ زیرا انتخاب زمان‌بندی نویز، گام‌های حل عددی و پارامترسازی شبکه را از یکدیگر تفکیک می‌کند [۵۸، ۳۱].

⁴Stochastic Differential Equation

⁵Ordinary Differential Equation

۴.۱.۲ نمونه‌برداری، DDIM و هدایت تولید

یکی از محدودیت‌های اولیه مدل‌های انتشار، نیاز به تعداد زیاد گام‌های نمونه‌برداری بود. DDIM^۶ نشان داد که می‌توان با تعریف یک مسیر غیرمارکوفی، نمونه‌برداری را با گام‌های کمتر انجام داد، در حالی که از همان شبکه آموزش دیده استفاده می‌شود [۵۶]. ابتدا تخمین تصویر پاک از روی نمونه نویزی محاسبه می‌شود:

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t, c)}{\sqrt{\bar{\alpha}_t}}. \quad (2.1.11)$$

سپس نمونه گام قبلی با ترکیب $\hat{x}_0$ و نویز پیش‌بینی شده ساخته می‌شود. در حالت کلی:

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \epsilon_\theta(x_t, t, c) + \sigma_t z, \quad (2.1.12)$$

که در آن $z \sim \mathcal{N}(0, I)$ است. با انتخاب $\sigma_t = 0$ ، فرایند نمونه‌برداری قطعی می‌شود و می‌تواند با تعداد گام کمتر اجرا گردد. در مدل‌های شرطی، علاوه بر سرعت نمونه‌برداری، کنترل خروجی نیز اهمیت دارد. راهنمایی بدون طبقه‌بند^۷ خروجی شرطی و بی‌شرط مدل را با یکدیگر ترکیب می‌کند [۲۶]:

$$\epsilon_{\text{cfg}} = \epsilon_\theta(x_t, t, \emptyset) + w (\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)), \quad (2.1.13)$$

که در آن w شدت هدایت را کنترل می‌کند. این رابطه برای این پایان‌نامه نیز مهم است، زیرا در تنظیمات آزمایش از CFG برای بهبود وفاداری شرطی نمونه‌ها استفاده شده است.

۲.۲ مدل‌های انتشار مبتنی بر مبدل

پس از تثبیت چارچوب‌های احتمالاتی، مبتنی بر امتیاز و پیوسته در مدل‌های انتشار، تمرکز پژوهش‌ها از تعریف فرایند حذف نویز به سمت طراحی معماری شبکه حذف نویز تغییر کرد؛ زیرا کیفیت

^۶Denoising Diffusion Implicit Models

^۷Classifier-Free Guidance

جدول ۲.۱.۱: مقایسه چارچوب‌های اصلی مدل‌های انتشار

چارچوب	ایده اصلی	رابطه یا هدف کلیدی
DDPM	مدل‌سازی گسسته مسیر نویزدهی و حذف نویز	پیش‌بینی $\epsilon_\theta(x_t, t, c)$ با خطای میانگین مربعات
مدل‌های مبتنی بر یادگیری گرادیان لگاریتم چگالی	داده‌های نویزی	$s_\theta(x_t, t) \approx \nabla_{x_t} \log q_t(x_t)$
SDE/ODE	بیان پیوسته فرایند نویزدهی و تولید	$dx = f(x, t)dt + g(t)dw$
DDIM	و کاهش تعداد گام‌های تولید با مسیره‌های جایگزین	بازسازی $\hat{x}_0$ از روی x_t و ϵ_θ
نمونه‌بردارها		

تولید فقط به تابع هدف انتشار وابسته نیست و عواملی مانند فضای نمایش، زمان‌بندی نویز، نوع شرط‌گذاری، نمونه‌بردار و ساختار شبکه نیز در عملکرد نهایی اثر دارند [۱۱، ۵۳، ۴۹]. در همین مسیر، موفقیت مبدل‌ها در پردازش توالی و سپس در بینایی ماشین باعث شد پژوهشگران از معماری‌های مبتنی بر توجه برای مدل‌های مولد تصویری استفاده کنند [۵۹، ۱۶]. برخلاف U-Net ها و شبکه‌های پیچشی که سوگیری محلی قوی دارند، مبدل‌ها با مدل‌سازی وابستگی‌های دوربرد میان توکن‌های تصویری می‌توانند ساختار سراسری تصویر را بهتر دنبال کنند؛ هرچند نبود سوگیری محلی ذاتی، هزینه توجه و نیاز به حفظ جزئیات مکانی همچنان چالش‌های مهمی هستند [۳۵، ۷۳، ۱۸]. بنابراین، مسئله اصلی این بخش آن است که چگونه می‌توان نقش تابع ϵ_θ را از یک بدنه اصلی پیچشی به یک معماری مبدلی منتقل کرد و در عین حال شرط زمانی، شرط کلاسی و اطلاعات مکانی تصویر را به‌صورت پایدار حفظ نمود [۴۶، ۴، ۲].

۱.۲.۲ مدل GenViT

مدل GenViT^۸ یکی از تلاش‌های اولیه برای بررسی این ایده بود که آیا می‌توان بدنه اصلی مدل انتشار را با یک ViT خالص پیاده‌سازی کرد یا نه [۶۹]. اهمیت این مدل در آن است که پیش از


^۸Generative ViT

تثبیت خانواده DiT، امکان استفاده از توکن‌های تصویری و اطلاعات گام زمانی در یک معماری تمام‌مبدلی را بررسی کرد.

در GenViT، توکن‌های تصویر نویزی همراه با اطلاعات زمان پردازش می‌شوند و تابع زیان، یادگیری تولیدی و تمایزگر را در کنار یکدیگر قرار می‌دهد:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{diff}} + \lambda \mathcal{L}_{\text{cls}} \quad (2.2.14)$$

که در آن $\mathcal{L}_{\text{diff}}$ خطای بازسازی نویز و $\mathcal{L}_{\text{cls}}$ خطای دسته‌بندی است. این مدل از نظر تاریخی نشان می‌دهد که مبدل‌ها فقط برای استخراج ویژگی تصویری به کار نمی‌روند، بلکه می‌توانند در خود مسیر تولید نیز نقش داشته باشند. نمای کلی این معماری در شکل ۲.۲.۱ نمایش داده شده است [۶۹].



شکل ۲.۲.۱: معماری GenViT که مبدل را در مدل انتشار ادغام می‌کند.

۲.۲.۲ مدل U-ViT


مدل U-ViT^۹ مسئله دیگری را برجسته کرد: اگر شبکه حذف نویز کاملاً مبدلی باشد، چگونه می‌توان اطلاعات سطح پایین و جزئیات مکانی را در مسیر عمیق مدل حفظ کرد؟ باثو و همکاران با الهام از شکل U-Net، اتصالات پرشی بلند^{۱۰} را میان بلوک‌های کم‌عمق و عمیق مبدل وارد کردند تا

^۹U-shaped Vision Transformer

^{۱۰}Long Skip Connections

اطلاعات محلی در طول فرایند حذف نویز از بین نرود [۱].

در U-ViT، تصویر نویزی، زمان و شرطهایی مانند برچسب کلاس همگی به صورت توکن پردازش می‌شوند و تخمین نویز $\epsilon_\theta(x_t, t, c)$ توسط یک شبکه تمام‌مبدلی انجام می‌گیرد. شکل ۲.۲.۲ ساختار کلی این مدل را نشان می‌دهد. اهمیت U-ViT برای این پایان‌نامه در آن است که نشان می‌دهد حتی در معماری‌های مبدلی نیز مسیرهای میان‌بر و چندسطحی برای حفظ جزئیات مکانی ضروری هستند [۱].



شکل ۲.۲.۲: معماری U-ViT با اتصالات پرشی بلند بین بلوک‌های مبدل [۱].

۳.۲.۲ مدل DiT

مدل مبدل انتشار^{۱۱} (DiT) نقطه محوری این فصل است، زیرا نشان می‌دهد در مدل انتشار می‌توان معماری حذف نویز را از U-Net به یک بدنه اصلی تمام‌مبدلی منتقل کرد، بدون آن‌که فرمول‌بندی


¹¹Diffusion Transformer

انتشار تغییر کند [۴۶]. این مدل روی فضای نهان^{۱۲} عمل می‌کند؛ یعنی ابتدا تصویر به نمایش فشرده‌تری تبدیل می‌شود و سپس این نمایش به پیچ‌ها و توکن‌ها شکسته می‌شود. پیلز و شی نشان دادند که با افزایش تعداد پارامترها و حجم محاسبات، کیفیت تولید تصویر در این خانواده به‌صورت پیوسته بهبود می‌یابد.

معماری DiT از بلوک‌های استاندارد ViT استفاده می‌کند، اما برای تزریق اطلاعات زمان و کلاس از نرمال‌سازی لایه تطبیقی با مقداردهی صفر (adaLN-Zero^{۱۳}) بهره می‌برد. در این سازوکار، پارامترهای مقیاس (γ) و انتقال (β) در لایه‌های نرمال‌سازی از بردار زمان و کلاس پیش‌بینی می‌شوند:

$$\text{adaLN}(h, t, c) = \gamma(t, c) \odot \text{Norm}(h) + \beta(t, c) \quad (2.2.15)$$

این روش، شرط‌گذاری را درون بلوک‌های مبدل وارد می‌کند و به مدل اجازه می‌دهد فرایند حذف نویز را در فضای فشرده‌تری نسبت به پیکسل‌ها انجام دهد. شکل ۲.۲.۳ ساختار کلی این معماری را نشان می‌دهد [۴۶]. از آنجا که معماری پیشنهادی این پایان‌نامه نیز یک شاخه مکمل را در کنار بدنه اصلی DiT قرار می‌دهد، این مدل مرجع اصلی برای تحلیل‌های بعدی فصل است.



شکل ۲.۲.۳: معماری DiT مبتنی بر بلوک‌های استاندارد مبدل و adaLN.

¹²Latent Space


¹³Adaptive Layer Normalization with Zero Initialization

مدل DiffiT^{۱۴} بر محدودیت دیگری در مبدل‌های انتشار تمرکز دارد: نحوه وارد کردن زمان در فرایند توجه [۲۲]. در DiT، زمان و کلاس عمدتاً از مسیر نرمال‌سازی تطبیقی وارد بلوک‌ها می‌شوند، اما DiffiT یک مکانیزم خود توجه وابسته به زمان^{۱۵} معرفی می‌کند تا ماتریس‌های توجه نیز مستقیماً از گام زمانی اثر بگیرند.

در این مدل، توکن زمان به صورت پویا در لایه‌های توجه حضور دارد و رابطه توجه ضرب داخلی مقیاس شده، که در رابطه ۱.۶.۴ معرفی شد، با پرسش، کلید و مقدار وابسته به زمان نوشته می‌شود:

$$\text{Attention}(Q_t, K_t, V_t) = \text{softmax} \left(\frac{Q_t K_t^T}{\sqrt{d_k}} \right) V_t \quad (۲.۲.۱۶)$$

که در آن Q_t, K_t, V_t با استفاده از تعبیه‌های مکانی و زمانی مشترک محاسبه می‌شوند. این طراحی به مدل اجازه می‌دهد پویایی حذف نویز را با دقت بیشتری دنبال کند و در عین حال، با ساختار چندوضوحی خود بخشی از هزینه محاسباتی را کنترل نماید. شکل ۲.۲.۴ نمایی از این ساختار را ارائه می‌کند [۲۲].



شکل ۲.۲.۴: معماری DiffiT با بلوک‌های توجه وابسته به زمان (TMSA).


مدل LaVin-DiT^{۱۶} ادامه مسیر مقیاس‌پذیری در خانواده DiT است و رفتار مدل‌های انتشار

¹⁴Diffusion Vision Transformer

¹⁵Time-Dependent Self-Attention - TMSA

¹⁶Large Vision Diffusion Transformer

بصری را در مقیاس‌های بزرگ‌تر بررسی می‌کند [۷۱]. این مدل از این جهت در پیشینه قرار می‌گیرد که نشان می‌دهد پرسش اصلی فقط جایگزین کردن U-Net با مبدل نیست، بلکه فهم رابطه میان اندازه مدل، حجم محاسبات، کیفیت تولید و هزینه آموزش نیز اهمیت دارد. شکل ۲.۲.۵ معماری پیشنهادی این مدل را نشان می‌دهد.




شکل ۲.۲.۵: معماری پیشنهادی در LaVin-DiT برای بهبود مقیاس‌پذیری [۷۱].

LightningDiT یکی از کارهای جدید در مسیر تقویت مدل‌های انتشار مبتنی بر مبدل است که روی دشواری بهینه‌سازی میان بازسازی نمایش نهان و توان تولید تصویر تمرکز می‌کند [۷۰]. این کار نشان می‌دهد که در مدل‌های انتشار نهان، کیفیت نهایی فقط به ظرفیت مبدل وابسته نیست، بلکه به تعادل میان کیفیت بازسازی فضای نهان، راهبرد آموزش و مسیر تولید نیز بستگی دارد. از این رو، LightningDiT با بهبود فرایند آموزش مبدل انتشار نهان، به یک مبنای قوی از نظر FID تبدیل شده است.

۳.۲ روندهای تکمیلی در مدل‌های انتشار مبتنی بر مبدل

یکی از محورهای اصلی در پیشینه مدل‌های انتشار مبتنی بر مبدل، مسئله مقیاس‌پذیری است. مدل‌های اولیه نشان دادند که با افزایش اندازه شبکه و مقدار محاسبات، کیفیت تولید تصویر بهبود می‌یابد؛ اما این بهبود معمولاً با افزایش شدید هزینه آموزش و استنتاج همراه است. به همین دلیل، پژوهش‌های

جدید تلاش کرده‌اند میان ظرفیت مدل، سرعت آموزش و کیفیت نمونه‌های تولیدی تعادل برقرار کنند. برای نمونه، مدل‌های مبتنی بر ماسک‌گذاری و یادگیری با توکن‌های تصویری نشان داده‌اند که می‌توان با کاهش بخشی از محاسبات غیرضروری، آموزش مدل‌های انتشار را سریع‌تر کرد [۴۳، ۱۹]. همچنین چارچوب‌هایی مانند FiTv2^{۱۷}، EDT^{۱۸} و مدل‌های پویای مبدل انتشار، با تغییر طراحی بلوک‌ها، مسیرهای محاسباتی یا سیاست پردازش توکن‌ها تلاش کرده‌اند کیفیت تولید را در کنار کاهش هزینه محاسباتی حفظ کنند [۶۴، ۹، ۷۷، ۷۶]. در همین امتداد، مدل Q-DiT^{۱۹} راهکاری برای فشرده‌سازی مدل‌های DiT از طریق کوانتیزاسیون پس از آموزش ارائه می‌دهد که در شکل ۲.۳.۶ نمایش داده شده است [۷۲]. این روش با کاهش دقت نمایش وزن‌ها و فعال‌سازی‌ها، بدون نیاز به آموزش مجدد سنگین، کارایی استنتاج را افزایش می‌دهد و نشان می‌دهد که مسئله کارایی تنها به طراحی معماری محدود نیست، بلکه به نحوه نمایش و اجرای پارامترها نیز وابسته است.



شکل ۲.۳.۶: شماتیک روش کوانتیزاسیون در Q-DiT [۷۲].

در تولید تصویر با وضوح بالا، چالش فقط افزایش تعداد پارامترها نیست؛ بلکه حفظ جزئیات محلی، جلوگیری از اعوجاج و مدیریت وابستگی‌های چندمقیاسی نیز اهمیت دارد. مدل‌هایی مانند

¹⁷Flexible Vision Transformer v2

¹⁸Efficient Diffusion Transformer

¹⁹Accurate Post-Training Quantization for Diffusion Transformers

PixArt-Alpha و نسخه پیشرفته‌تر آن PixArt-Sigma با تمرکز بر آموزش کارآمد مدل‌های انتشار نشان دادند که می‌توان با طراحی مناسب داده، شرط‌گذاری متنی و سازمان‌دهی توکن‌ها، تولید متن-به-تصویر را در وضوح‌های بالا بهبود داد [۷، ۸]. همچنین چارچوب‌های مبتنی بر Rectified Flow، از جمله مدل مورد استفاده در نسل سوم Stable Diffusion و معماری MM-DiT^{۲۰}، با استفاده از مدل‌های مقیاس‌پذیر و پردازش جداگانه اطلاعات تصویری و متنی، مسیر دیگری برای تولید تصاویر با کیفیت بالا فراهم کرده‌اند [۱۷]. از سوی دیگر، روش‌های چندوضوحی و زمان‌وابسته نشان داده‌اند که کنترل بهتر اطلاعات در سطوح مکانی مختلف می‌تواند به کاهش اعوجاج و بازسازی بهتر ساختارهای تصویری کمک کند [۳۷]. این جهت‌گیری‌ها از نظر مفهومی با انگیزه این پژوهش همسو هستند، زیرا معماری پیشنهادی نیز تلاش می‌کند با افزودن شاخه‌ای سبک و وضوح‌بالا، جزئیات مکانی را بدون آموزش مجدد کل مدل تقویت کند.

۱.۳.۲ تولید شرطی

بخش مهم دیگری از پیشینه، به کنترل‌پذیری و شخصی‌سازی مدل‌های انتشار مربوط است. مدل‌های ترکیبی نشان داده‌اند که می‌توان چندین شرط یا مفهوم بصری را در فرایند تولید با یکدیگر ترکیب کرد و از این طریق کنترل معنایی دقیق‌تری بر خروجی به دست آورد [۳۶]. روش‌های مبتنی بر مدولاسیون توجه نیز برای تولید متن-به-تصویر متراکم و کنترل‌شده استفاده شده‌اند و نشان داده‌اند که تغییر در نقشه‌های توجه می‌تواند روی جای‌گذاری و انسجام اجزای تصویر اثرگذار باشد [۳۲]. همچنین پژوهش‌هایی مانند یادگیری درون‌متنی برای مدل‌های انتشار، تولید شخصی‌سازی‌شده بدون تنظیم زمان آزمون، و تزریق سبک، نشان می‌دهند که سازگار کردن مدل‌های بزرگ با مفهوم یا سبک جدید، یکی از مسائل فعال و مهم در تولید تصویر است [۶۳، ۴۰، ۱۰]. این روند با بحث هدایت تولید در بخش ۱.۲ پیوستگی دارد، زیرا کنترل‌پذیری در عمل به ترکیب شرط‌گذاری، نمونه‌برداری و معماری شبکه حذف نویز وابسته است.

²⁰Multimodal Diffusion Transformer

۲.۳.۲ کاربردها


مدل‌های انتشار علاوه بر تصویر دوبعدی، به حوزه‌هایی مانند ویدئو، داده‌های سه‌بعدی و تصویر پزشکی نیز گسترش یافته‌اند. در تولید ویدئو، مدل‌هایی مانند Video Diffusion Models، LaVie و Latte نشان داده‌اند که چالش اصلی، حفظ سازگاری زمانی در کنار کیفیت بصری فریم‌ها است [۲۷، ۶۲، ۴۱]. در حوزه سه‌بعدی نیز پژوهش‌هایی مانند ویرایش سه‌بعدی فعال‌سازی‌های مدل‌های انتشار یا تولید تصویر استریو نشان می‌دهند که بازنمایی‌های آموخته‌شده در مدل‌های انتشار می‌توانند به فراتر از تولید تصویر دوبعدی تعمیم یابند [۴۵، ۶۱]. همچنین در کاربردهای پزشکی و علمی، تولید تصاویر اخت‌فیزیکی، سنتز CT^{۲۱} و تحلیل تصاویر بافت‌شناسی نمونه‌هایی از استفاده مدل‌های مولد و مبدل‌ها در دامنه‌های تخصصی هستند [۷۸، ۳۰، ۶۷]. این گسترش کاربردها نشان می‌دهد که روش‌های سبک و قابل تنظیم، برای انتقال مدل‌های بزرگ به دامنه‌های جدید اهمیت زیادی دارند.

در همین امتداد، مدل DiT-3D^{۲۲} معماری مبدل‌های انتشار را به تولید Voxelized Point Clouds تعمیم می‌دهد [۴۲]. در این مدل، داده حجمی به پچ‌های سه‌بعدی تقسیم می‌شود و پس از ترکیب با تعبیه‌های موقعیتی سه‌بعدی، به دنباله‌ای از توکن‌ها تبدیل می‌گردد. برای کنترل هزینه محاسباتی ناشی از طول زیاد توکن‌ها در فضای حجمی، DiT-3D از توجه پنجره‌ای سه‌بعدی^{۲۳} استفاده می‌کند و تعاملات را به نواحی محلی محدود می‌سازد. جایگاه این مدل در فصل حاضر بیشتر از زاویه گسترش دامنه کاربرد است، زیرا نشان می‌دهد ایده پچ‌سازی و توجه در DiT می‌تواند از تولید تصویر دوبعدی به داده‌های حجمی نیز منتقل شود. این معماری در شکل ۲.۳.۷ آمده است.

^{۲۱}Computed Tomography

^{۲۲}Three-Dimensional Diffusion Transformer

^{۲۳}3D Window Attention



شکل ۲.۳.۷: معماری DiT-3D: تعمیم مکانیزم پچ‌سازی و توجه به فضای حجمی برای تولید سه‌بعدی [۴۲].


۳.۳.۲ محلیت و ویژگی‌های ریزدانه

با وجود قدرت مبدل‌ها در مدل‌سازی وابستگی‌های سراسری، حفظ محلیت و جزئیات ریزدانه همچنان یک مسئله مهم است. پژوهش‌های مربوط به محلیت در مبدل‌های بینایی نشان می‌دهند که نبود سوگیری مکانی محلی می‌تواند در برخی وظایف به ضعف در نمایش بافت‌ها و ساختارهای کوچک منجر شود [۳۵]. از سوی دیگر، روش‌هایی که به سازگاری فرکانسی یا تنظیم حافظه‌کارا در مبدل‌های بینایی می‌پردازند، نشان می‌دهند که بخش‌های مختلف طیف فرکانسی و لایه‌های مختلف شبکه نقش یکسانی در انتقال دانش ندارند [۱۵، ۷۵، ۳۹].

۴.۲ معماری‌های جریان دوگانه

استفاده از معماری‌های جریان دوگانه^{۲۴} یکی از راهکارهای رایج برای ترکیب اطلاعات سراسری و محلی در پردازش تصویر است. ایده اصلی این رویکرد آن است که یک مسیر شبکه می‌تواند ساختارهای کلی، وابستگی‌های بلندبرد و ویژگی‌های معنایی را مدل کند، در حالی که مسیر دیگر روی جزئیات محلی، لبه‌ها، بافت‌ها و مؤلفه‌های فرکانس بالا تمرکز دارد. برای نمونه، HRNet^{۲۵} با حفظ نمایش‌های وضوح بالا در طول کل فرایند پردازش و تبادل مداوم اطلاعات با شاخه‌های وضوح پایین‌تر، نشان داد که نگه داشتن اطلاعات مکانی دقیق برای وظایفی مانند تشخیص نقاط کلیدی، قطعه‌بندی و بازشناسی بصری اهمیت زیادی دارد [۶۰].

شکل ۲.۴.۸ ایده اصلی HRNet را نشان می‌دهد: به جای آن‌که شبکه ابتدا نمایش تصویر را به وضوح پایین فشرده و سپس در انتها آن را بازیابی کند، شاخه وضوح بالا در تمام مراحل حفظ می‌شود و با شاخه‌های کم‌وضوح‌تر تبادل اطلاعات دارد. این طراحی از نظر مفهومی برای پژوهش حاضر مهم است، زیرا نشان می‌دهد حفظ یک مسیر پر جزئیات می‌تواند مکمل مسیرهای معنایی و کم‌وضوح باشد [۶۰].



شکل ۲.۴.۸: واحد تجمیع چندوضوحی در HRNet: شاخه وضوح بالا در کنار شاخه‌های کم‌وضوح‌تر حفظ شده و اطلاعات میان وضوح‌ها به صورت مکرر مبادله می‌شود [۶۰].


²⁴Dual-Stream Architectures

²⁵High-Resolution Network

در حوزه مبدل‌های بینایی، مدل‌هایی مانند CrossViT^{۲۶} این ایده را با استفاده از دو شاخه مبتنی بر اندازه پچ‌های متفاوت پیاده‌سازی کرده‌اند [۵]. در این معماری، که در شکل ۲.۴.۹ نشان داده شده است، شاخه‌ای با پچ‌های بزرگ‌تر برای دریافت زمینه سراسری و شاخه‌ای با پچ‌های کوچک‌تر برای استخراج جزئیات محلی به کار می‌رود. سپس اطلاعات دو شاخه با سازوکار توجه متقابل میان توکن‌های خلاصه‌ساز مبادله می‌شود. پژوهش‌های مرتبط با طراحی مبدل‌های چندمقیاسی نیز نشان می‌دهند که افزایش دامنه دریافت^{۲۷} در کنار حفظ مسیرهای محلی، برای تحلیل تصویر با وضوح بالا اهمیت کلیدی دارد [۳۵، ۷۳]. همچنین در مدل‌های انتشار مبتنی بر مبدل مانند U-ViT، استفاده از مسیرهای چندسطحی و اتصالات بلندبرد، کارایی مشابهی در حفظ اطلاعات جزئیات ایجاد می‌کند [۱].


^{۲۶}Cross-Attention Multi-Scale Vision Transformer

^{۲۷}Receptive Field



شکل ۲.۴.۹: معماری دوجریانی CrossViT: شاخه‌های بزرگ‌تر زمینه سراسری را مدل می‌کند و شاخه‌های کوچک‌تر جزئیات محلی را حفظ می‌کند؛ تبادل اطلاعات میان دو شاخه از طریق توجه متقابل انجام می‌شود [۵].

در CrossViT چند راهبرد برای ادغام دو شاخه بررسی شده است: ادغام کامل همه توکن‌ها، ادغام توکن‌های کلاس، ادغام مکانی جفت‌به‌جفت، و ادغام مبتنی بر توجه متقابل. نتیجه مهم این مقایسه آن است که برای انتقال اطلاعات چندمقیاسی الزاماً نیازی به ترکیب پرهزینه همه توکن‌ها نیست؛ گاهی یک توکن خلاصه‌ساز می‌تواند نقش واسطه فشرده و کارآمدی میان شاخه‌ها داشته باشد. شکل ۲.۴.۱۰ این تفاوت را به صورت شماتیک نشان می‌دهد [۵].



شکل ۲.۴.۱۰: راهبردهای مختلف ادغام ویژگی در CrossViT، از ادغام همه توکن‌ها تا توجه متقابل مبتنی بر توکن کلاس [۵].

در سمت مدل‌های انتشار، بازگشت کوتاه به U-ViT از زاویه معرفی مدل نیست، بلکه از زاویه حفظ اطلاعات چندسطحی است. همان‌طور که در شکل ۲.۲.۲ دیده می‌شود، اتصالات بلند میان بلوک‌های ابتدایی و انتهایی مبدل کمک می‌کنند اطلاعات سطح پایین و جزئیات مکانی در مسیر حذف نویز از بین نروند. این نکته، پیوند مستقیمی میان ایده‌های جریان دوگانه و نیاز مدل‌های انتشار به حفظ جزئیات محلی ایجاد می‌کند [۱].

جدول ۲.۴.۲ خلاصه می‌کند که هر یک از این معماری‌ها چه نوع مسیری برای حفظ اطلاعات محلی یا چندمقیاسی ایجاد می‌کنند. در هر سه نمونه، یک مسیر کم‌هزینه برای نگه‌داری یا انتقال اطلاعات ریزدانه در کنار مسیر اصلی دیده می‌شود؛ تفاوت در آن است که HRNet این کار را با شاخه‌های وضوح متفاوت، CrossViT با شاخه‌های پچی متفاوت و توجه متقابل، و U-ViT با اتصالات بلند میان لایه‌های مبدل انجام می‌دهد [۱، ۵، ۶۰].

این شواهد نشان می‌دهند که ترکیب هم‌زمان ویژگی‌های درشت‌دانه و ریزدانه می‌تواند برای پردازش تصاویر با وضوح بالا مفید باشد.

جدول ۲.۴.۲: مقایسه معماری‌های جریان دوگانه		
معماری	مکانیزم اصلی	نوع اطلاعات حفظ شده
HRNet	نگهداری هم‌زمان شاخه‌های وضوح بالا و پایین با تجمیع چندوضوحی تکرارشونده	جزئیات مکانی، لبه‌ها و بافت‌های محلی
CrossViT	دو شاخه با اندازه پچ متفاوت و تبادل اطلاعات از طریق توکن‌های کلاس و توجه متقابل	زمینه سراسری در کنار جزئیات ریزدانه مبتنی بر پچ‌های کوچک‌تر
U-ViT	اتصال‌های بلند میان بلوک‌های ابتدایی و انتهایی مبدل در شبکه انتشار	اطلاعات سطح پایین و چندمرحله‌ای در مسیر حذف نویز


۵.۲ تجمیع ویژگی و توکن

در معماری استاندارد مبدل بینایی، یک توکن ویژه به نام توکن کلاس^{۲۸} به ابتدای توالی ورودی افزوده می‌شود تا در طول لایه‌های توجه، اطلاعات کل تصویر را به صورت فشرده در خود تجمیع کند [۱۶]. این توکن برای وظایفی مانند طبقه‌بندی تصویر مناسب است، زیرا مدل در پایان می‌تواند بازنمایی سراسری تصویر را از آن استخراج کند. با این حال، در معماری‌های چندشاخه یا جریان دوگانه، یک توکن سراسری واحد همیشه برای حفظ جزئیات محلی کافی نیست؛ زیرا ممکن است هنگام فشرده‌سازی کل تصویر، بخشی از اطلاعات ریزدانه و مکانی از دست برود.

راهبرد توکن‌های کلاس محلی بر این ایده استوار است که به جای استفاده از یک توکن خلاصه‌ساز برای کل تصویر، می‌توان برای هر ناحیه یا گروهی از توکن‌ها یک توکن خلاصه‌ساز جداگانه تعریف کرد. اگر نمایش محلی توکن‌ها را با X_l نشان دهیم، توکن محلی می‌تواند در نقش «پرس‌وجو» (Q) عمل کند و اطلاعات مهم را از «کلیدها» (K) و «مقادیر» (V) متناظر با همان گروه استخراج کند. محاسبه توجه در این حالت همان رابطه ۱.۶.۴ است، اما Q ، K و V فقط از توکن‌های همان گروه

²⁸Class Token

محلی ساخته می‌شوند [۵، ۱۶]. سازوکارهای مشابه در معماری‌هایی مانند CrossViT برای تبادل اطلاعات میان شاخه‌های چندمقیاسی استفاده شده‌اند؛ نمونه‌ای از این سازوکار در شکل ۲.۵.۱۱ آمده است [۵].



شکل ۲.۵.۱۱: ماژول توجه متقابل در CrossViT: توکن کلاس یک شاخه نقش پرس و جو را دارد و اطلاعات را از توکن‌های شاخه دیگر دریافت می‌کند [۵].

۶.۲ روش‌های تنظیم دقیق

تنظیم دقیق کامل به عنوان رویکرد پایه در تغییر رفتار مدل‌های بزرگ، شامل آزادسازی و به‌روزرسانی تمام پارامترهای شبکه در طول آموزش روی وظیفه یا دامنه هدف است. این فرآیند نسبت به روش‌های تنظیم دقیق پارامتر-کارا، پیچیدگی و هزینه بسیار بیشتری دارد چرا که شبکه‌های امروزی ممکن است دارای میلیاردها پارامتر باشند. همین ویژگی موجب مصرف بالای حافظه GPU^{۲۹}، نیاز به ذخیره‌سازی فعال‌سازی‌ها برای کل لایه‌ها، و افزایش زمان هر گام یادگیری می‌شود [۶۸].

۱.۶.۲ تنظیم دقیق پارامتر-کارا

تنظیم دقیق پارامتر-کارا در سال‌های اخیر به عنوان پاسخی عملی به محدودیت‌های زمان و منابع موردنیاز برای آموزش مدل‌های بزرگ مطرح شده است. ایده اصلی کاهش تعداد پارامترهایی است که طی فرآیند تنظیم دقیق به‌روز می‌شوند تا فشار حافظه، هزینه محاسباتی و مدت زمان آموزش کمتر شود، در حالی که کیفیت خروجی در سطح رقابتی باقی بماند [۵۴]. در این رویکردها بخش اعظم وزن‌های شبکه ثابت نگه داشته شده و تنها مجموعه کوچکی از پارامترهای افزوده‌شده یا انتخاب‌شده برای یادگیری آزاد هستند. FineDiffusion یک روش تنظیم دقیق پارامتر-کارا برای تولید تصویر شرطی ریزدانه است که مسئله مقیاس‌پذیری تولید کلاسی را در تعداد زیاد کلاس‌ها بررسی می‌کند [۴۴]. ایده اصلی این روش آن است که برای سازگار کردن مدل انتشار با کلاس‌های ریزدانه، لازم نیست همه وزن‌های شبکه آزاد شوند؛ در عوض می‌توان بخش محدودی از پارامترهای مؤثر بر شرط‌گذاری و تطبیق آماری مدل را به‌روزرسانی کرد. این بخش‌ها شامل تعبیه‌های کلاسی، بایاس‌ها و پارامترهای مرتبط با نرمال‌سازی هستند؛ یعنی اجزایی که رفتار شرطی مدل را تغییر می‌دهند، اما بدنه اصلی تولیدکننده را تا حد زیادی حفظ می‌کنند.

در این فصل، پیشینه پژوهش‌های مرتبط با معماری پیشنهادی از چهار زاویه بررسی شد. نخست، چارچوب‌های اصلی مدل‌های انتشار و مسیر حرکت آن‌ها به سمت مدل‌های مبتنی بر مبدل توضیح

²⁹Graphics Processing Unit

داده شد و نمونه‌هایی مانند LightningDiT و LaVin-DiT، DiffiT، DiT، U-ViT، GenViT نشان دادند که مبدل‌ها می‌توانند به بدنه اصلی مدل‌های انتشار تبدیل شوند. دوم، روندهای تکمیلی حوزه نشان دادند که مقیاس‌پذیری، کارایی، شرط‌پذیری و حفظ جزئیات محلی همچنان چالش‌های مهم این خانواده از مدل‌ها هستند. سوم، معماری‌های جریان دوگانه و چندوضوحی مانند HRNet و CrossViT نشان دادند که ترکیب یک مسیر سراسری با مسیری محلی می‌تواند راهکاری مؤثر برای حفظ جزئیات ریزدانه باشد. چهارم، روش‌های تنظیم دقیق پارامتر-کارا، به‌ویژه FineDiffusion، نشان دادند که می‌توان بدون به‌روزرسانی کامل مدل پایه، مسیرهای جدیدی برای سازگارسازی و تزریق ویژگی ایجاد کرد [۱۱، ۴۶، ۶۰، ۵، ۵۴، ۴۴].

فصل ۳

معماری پیشنهادی: DuoDiT

در این فصل، معماری پیشنهادی این پژوهش با عنوان DuoDiT معرفی می‌شود. هدف این معماری، تنظیم دقیق پارامتر-کارای مدل‌های انتشار مبتنی بر مبدل (DiT) برای کلاس‌ها یا دامنه‌های هدف است؛ به گونه‌ای که بدون به‌روزرسانی کامل بدنه اصلی، مسیر جداگانه‌ای برای استخراج و تزریق ویژگی‌های محلی فراهم شود. چالش اصلی در این مسئله آن است که تنظیم دقیق کامل مدل‌های بزرگ هزینه محاسباتی و حافظه‌ای بالایی دارد و در عین حال، روش‌های بسیار فشرده ممکن است برای تغییر بازنمایی‌های مکانی و حفظ جزئیات محلی کافی نباشند [۴۶، ۵۴].

معماری DuoDiT بر یک ساختار دوجریانی (Dual-Stream Architecture) استوار است. جریان نخست، بدنه اصلی DiT است که وزن‌های آن ثابت نگه داشته می‌شود و نقش حفظ دانش پیش‌آموزش‌دیده و ساختار معنایی تصویر را بر عهده دارد. جریان دوم، شاخه وضوح‌بالا یا شاخه x_2 است که با اندازه پچ کوچک‌تر عمل می‌کند و ویژگی‌های ریزدانه‌تری تولید می‌کند. روش اصلی این پژوهش برای هم‌تراز کردن خروجی شاخه x_2 با توکن‌های بدنه اصلی، مکانیزم «توکن‌های کلاس محلی» است؛ به این معنا که برای هر گروه محلی از چهار توکن وضوح‌بالا، یک توکن خلاصه‌ساز یادگیرنده تولید می‌شود و خروجی همین توکن به‌عنوان نماینده آن ناحیه به جریان اصلی افزوده می‌گردد.


[۴۶، ۵، ۱۶].

۱.۳ معماری مدل

سیستم پیشنهادی از دو بخش اصلی تشکیل شده است. بخش نخست، جریان بدنه اصلی منجمد (Frozen Backbone) است که همان مدل DiT-XL/2 بوده و وزن‌های آن، شامل تعبیه‌ساز پیچ، بلوک‌های مبدل و لایه‌های شرط‌گذاری اصلی، ثابت نگه داشته می‌شوند. این جریان بازنمایی اصلی نويز ورودی، زمان و برچسب کلاس را تولید می‌کند. بخش دوم، جریان وضوح بالا (x2 Stream) است که شامل تعبیه‌ساز پیچ با اندازه کوچک‌تر، بلوک مبدل شاخه کمکی، مکانیزم تجمیع مبتنی بر توکن کلاس محلی و پروژکشن‌های تطبیق ابعاد است. معماری از نظر طراحی امکان افزودن شرط‌گذاری FiLM را نیز دارد، اما این مؤلفه در آموزش اصلی ImageNet-1K فعال نشده است [۴۶، ۱۶، ۴۷].

در پیاده‌سازی نهایی این پژوهش، ادغام دو جریان به صورت جمع باقی‌مانده پس از آخرین بلوک مبدل بدنه اصلی انجام می‌شود؛ این همان تنظیمی است که در فصل آزمایش‌ها با نام `x2_final_fuse` گزارش شده است. بنابراین، گزینه‌هایی مانند ادغام متناوب در چندین بلوک، بخشی از فضای طراحی محسوب می‌شوند اما روش اصلی گزارش شده در این پایان‌نامه ادغام نهایی است [۴۶، ۵۹].

شکل ۳.۱.۱ نمای کلی جریان معماری پیشنهادی را نشان می‌دهد. در این نما، مسیر بدنه اصلی DiT در کنار شاخه وضوح بالا قرار گرفته و نقش مکانیزم توکن‌های کلاس محلی در فشرده‌سازی و انتقال ویژگی‌های شاخه x2 به جریان اصلی مشخص شده است.



شکل ۳.۱.۱: نمای کلی معماری پیشنهادی و جریان تجمیع ویژگی مبتنی بر توکن‌های کلاس محلی. شاخه وضوح بالا ویژگی‌های ریزدانه را استخراج کرده و توکن‌های کلاس محلی، اطلاعات هر گروه از توکن‌ها را برای ادغام با بدنه اصلی DiT فشرده می‌کنند.

۱.۱.۳ تعبیه‌ساز پیچ با وضوح بالا

در مدل استاندارد DiT-XL/2، ورودی نهان به پیچ‌های 2×2 تقسیم می‌شود. در شاخه x2، برای افزایش تفکیک مکانی اولیه، اندازه پیچ برابر $p' = 1$ در نظر گرفته شده است. اگر تعداد توکن‌های شاخه اصلی برابر T باشد، شاخه x2 چهار برابر آن، یعنی $4T$ توکن تولید می‌کند. این اختلاف

تعداد توکن‌ها باعث می‌شود پیش از ادغام با جریان اصلی، یک مرحله هم‌ترازسازی و کاهش طول توالی لازم باشد. روش اصلی این هم‌ترازسازی در این پژوهش، مکانیزم توکن کلاس محلی است [۱۶، ۴۶].


۲.۱.۳ روش‌های تجمیع ویژگی

سه راهبرد ساده‌تر برای کاهش طول توالی شاخه x_2 در نظر گرفته شده‌اند تا در فصل آزمایش‌ها با روش توکن کلاس محلی مقایسه شوند. این راهبردها بخشی از معماری نهایی نیستند، بلکه نقش مبنای مقایسه‌ای را دارند [۵، ۳۴].

تجمیع با پروجکشن خطی

در این روش، برای کاهش ابعاد و ادغام ویژگی‌های شاخه x_2 با بدنه اصلی، از مکانیسم الحاق و پروجکشن خطی استفاده می‌شود. برای هر ناحیه 2×2 از تصویر که متناظر با ۴ توکن در شاخه با وضوح بالا است، ویژگی‌ها به صورت برداری به یکدیگر متصل می‌شوند [۵، ۴۶]. فرض کنید Z_{x_2} ویژگی‌های ورودی باشند. برای هر موقعیت i ، چهار توکن $z_{4i}, z_{4i+1}, z_{4i+2}, z_{4i+3}$ وجود دارد. خروجی تجمیع شده z'_i به صورت زیر محاسبه می‌شود:

$$z'_i = W \cdot \text{Concat}(z_{4i}, z_{4i+1}, z_{4i+2}, z_{4i+3}) + b \quad (۳.۱.۱)$$



شکل ۳.۱.۲: نمای شماتیک از تجمیع ویژگی با استراتژی پروجکشن خطی. انطباق ۴ توکن ورودی به یک توکن خروجی با استفاده از پروجکشن خطی.

در این رابطه، W ماتریس وزن لایه خطی است که ابعاد فضای ویژگی ادغام شده را به ابعاد فضای هدف تطبیق می‌دهد. شکل ۳.۱.۲ این نگاشت چهار توکن ورودی به یک توکن خروجی را به صورت شماتیک نشان می‌دهد.

تجمیع با Max Pooling

در این رویکرد، برای استخراج ویژگی نهایی از هر پیچ، از عملیات Max Pooling استفاده می‌شود. این روش بر این فرض استوار است که بیشینه مقدار فعالیت در هر کانال ویژگی، بیانگر برجسته‌ترین

اطلاعات آن ناحیه است [۳۴]. برای هر گروه ۴ تایی از توکن‌ها که مربوط به یک پیچ از تصویر اصلی هستند، مقدار بیشینه در هر بعد ویژگی محاسبه می‌شود:


$$z'_{i,j} = \max(z_{4i,j}, z_{4i+1,j}, z_{4i+2,j}, z_{4i+3,j}) \quad (۳.۱.۲)$$

در اینجا $z'_{i,j}$ مقدار j -امین ویژگی از i -امین توکن خروجی است. این عملیات بدون استفاده از پارامترهای یادگیرنده انجام می‌شود.

تجمع با Min Pooling

این روش مشابه رویکرد Max Pooling است، با این تفاوت که از عملیات Min Pooling استفاده می‌کند. در اینجا تمرکز بر کمینه مقدار سیگنال در هر زیر-ناحیه است. رابطه ریاضی این تبدیل به صورت زیر تعریف می‌شود:

$$z'_{i,j} = \min(z_{4i,j}, z_{4i+1,j}, z_{4i+2,j}, z_{4i+3,j}) \quad (۳.۱.۳)$$




شکل ۳.۱.۳: مقایسه عملیات Max Pooling و Min Pooling. در سمت چپ، انتخاب بیشینه مقدار و در سمت راست، انتخاب کمینه مقدار مشاهده می‌شود.

این رویکرد نیز همانند روش بیشینه، یک عملیات ثابت و بدون وزن‌های قابل آموزش است که اطلاعات مکانی را با انتخاب اکستریم‌ها فشرده‌سازی می‌کند. شکل ۳.۱.۳ تفاوت انتخاب بیشینه و کمینه را در این نوع تجمیع نشان می‌دهد.

۳.۱.۳ روش تجميع ویژگی با توکن

در معماری نهایی DuoDiT، کاهش طول توالی شاخه x_2 به صورت یک عملیات یادگیرنده انجام می شود. در روش های ثابت مانند میانگین گیری یا بیشینه گیری، قاعده فشرده سازی مستقل از محتوای تصویر است؛ در نتیجه، همه گروه های محلی با یک قانون یکسان خلاصه می شوند. در مقابل، توکن کلاس محلی یک بردار یادگیرنده است که همراه با توکن های هر ناحیه پردازش می شود و می تواند بر اساس الگوی محلی همان ناحیه، بازنمایی فشرده تری تولید کند [۵، ۱۶، ۳۴].

در مدل های استاندارد ViT، یک توکن کلاس سراسری برای خلاصه سازی کل تصویر به کار می رود. در این پژوهش، همین ایده در مقیاس محلی استفاده شده است: هر چهار توکن شاخه x_2 که متناظر با یک توکن شاخه اصلی هستند، همراه با یک توکن کلاس محلی وارد بلوک پردازشی می شوند و خروجی توکن کلاس به عنوان نماینده همان ناحیه انتخاب می شود. بنابراین، خروجی شاخه x_2 از $4T$ توکن به T توکن کاهش می یابد و از نظر طول توالی با بدنه اصلی هم راستا می شود. شکل ۳.۱.۴ سازوکار گروه بندی توکن ها و استخراج خروجی محلی را نمایش می دهد [۵، ۱۶].



شکل ۳.۱.۴: نمای شماتیک از مکانیزم توکن کلاس محلی. توکن‌های داده در گروه‌های ۴ تایی به همراه یک توکن کلاس یادگیرنده وارد بلوک پردازشی شده و تنها توکن کلاس به عنوان خروجی انتخاب می‌شود.

فرآیند عملیاتی این روش شامل سه مرحله است. فرض کنید خروجی تعبیه‌ساز شاخه وضوح بالا با $Z_{x2} \in \mathbb{R}^{N \times 4T \times D}$ نمایش داده شود، که در آن N اندازه دسته، $4T$ طول توالی شاخه x_2 و D بعد ویژگی است. در گام نخست، توکن‌ها بر اساس موقعیت مکانی به گروه‌های چهارتایی تقسیم می‌شوند:

$$Z_{\text{grouped}} = \text{Reshape}(Z_{x2}) \in \mathbb{R}^{N \times T \times 4 \times D} \quad (3.1.4)$$

در این مرحله، T گروه مجزا وجود دارد که هر گروه شامل چهار بردار ویژگی $z_{4i}, z_{4i+1}, z_{4i+2}, z_{4i+3}$ است.

در گام دوم، یک پارامتر قابل یادگیری اولیه $C_{init} \in \mathbb{R}^{1 \times 1 \times D}$ تعریف می‌شود و برای تمام گروه‌ها و تمام نمونه‌های دسته گسترش می‌یابد. سپس این توکن به انتهای هر گروه چهارتایی الحاق می‌شود و ورودی محلی پنج‌توکنی شکل می‌گیرد:

$$Z_{\text{input}}^{(i)} = \text{Concat}([z_{4i}, \dots, z_{4i+3}, c_{\text{token}}^{(i)}]) \in \mathbb{R}^{5 \times D} \quad (۳.۱.۵)$$

که در آن $Z_{\text{input}}^{(i)}$ ورودی مربوط به i -امین پنجره محلی است.

در گام سوم، گروه‌های پنج‌تایی به صورت توالی $N \times 5T \times D$ بازآرایی می‌شوند و از بلوک مبدل شاخه $\times 2$ عبور می‌کنند. در پیاده‌سازی نهایی، محلی بودن تجمیع از طریق گروه‌بندی چهارتایی و استخراج خروجی توکن کلاس هر گروه اعمال می‌شود؛ به بیان دیگر، پس از پردازش، فقط موقعیت‌های متناظر با توکن‌های کلاس نگه داشته می‌شوند:

$$Z_{\text{processed}} = \text{TransformerEncoder}(Z_{\text{flattened}}) \quad (۳.۱.۶)$$

خروجی این تبدیل نیز دارای ابعاد $N \times 5T \times D$ است. وزن‌های بلوک مبدل و توکن کلاس محلی در طول آموزش تنظیم می‌شوند تا خروجی توکن کلاس بتواند بازنمایی فشرده‌ای از همان گروه محلی ایجاد کند.

در گام نهایی، از میان پنج خروجی مربوط به هر گروه، فقط بردار خروجی موقعیت توکن کلاس انتخاب می‌شود:

$$z'_i = Z_{\text{processed}}[i \times 5 + 4] \quad (۳.۱.۷)$$

(با فرض اینکه توکن کلاس در اندیس آخر، یعنی اندیس ۴ الحاق شده باشد). بدین ترتیب، خروجی نهایی شاخه کمکی با $Z_{\text{cls}} \in \mathbb{R}^{N \times T \times D}$ نمایش داده می‌شود و از نظر طول توالی با خروجی بدنه اصلی سازگار است.

۴.۱.۳ مبدل بینایی به عنوان خبره (ViT as Expert)


برای پردازش ویژگی‌های شاخه x_2 ، از یک بلوک مبدل برگرفته از مدل vit_large_patch16_224 استفاده شده است. این بلوک با وزن‌های پیش‌آموزش دیده مقداردهی اولیه می‌شود تا شاخه کمکی از ابتدا دارای بازنمایی‌های بصری قابل استفاده باشد. از آنجا که بعد پنهان این مدل ViT با بعد پنهان DiT-XL/2 یکسان نیست، پروجکشن‌های خطی ورودی و خروجی برای تبدیل ابعاد استفاده می‌شوند [۶۵، ۴۶، ۱۲، ۱۶].

۵.۱.۳ شرط‌گذاری اختیاری با FiLM

معماری DuoDiT از نظر طراحی می‌تواند شاخه x_2 را با مدولاسیون خطی ویژگی (FiLM) به گام زمانی نویز و برجسب کلاس وابسته کند، اما این گزینه در آموزش اصلی ImageNet-1K این پایان‌نامه فعال نشده است. بنابراین، نتایج فصل آزمایش‌ها بر اساس ویژگی‌های بدون مدولاسیون شاخه دوم گزارش می‌شوند و FiLM به عنوان یک مسیر توسعه اختیاری برای تنظیمات شرطی پیچیده‌تر باقی می‌ماند [۴۷، ۲۳].

در حالت فعال، بردار شرط $c = e_t + e_y$ ، که از ترکیب تعبیه زمان و تعبیه کلاس به دست می‌آید، به یک شبکه MLP داده می‌شود تا ضرایب مقیاس و انتقال تولید شوند. این ضرایب پیش از ورود ویژگی‌های شاخه x_2 به بلوک مبدل اعمال می‌شوند:

$$x'_2 = \gamma(c) \cdot x_2 + \beta(c) \quad (۳.۱.۸)$$



شکل ۳.۱.۵: بلوک شرط‌گذاری FiLM. بردار شرط c پارامترهای مقیاس و انتقال را تولید می‌کند که بر روی ورودی اعمال می‌شوند.

سازوکار تولید و اعمال ضرایب مقیاس و انتقال در شکل ۳.۱.۵ نشان داده شده است. بررسی اثر فعال‌سازی این ماژول در رژیم‌های شرطی ریزدانه‌تر می‌تواند به عنوان یکی از مسیرهای آینده دنبال شود.

۶.۱.۳ ادغام نهایی

پس از استخراج توکن‌های کلاس محلی، خروجی شاخه x_2 از نظر طول توالی با خروجی بدنه اصلی هم‌اندازه است. در معماری نهایی این پژوهش، ادغام فقط در انتهای بدنه اصلی انجام می‌شود. اگر خروجی آخرین بلوک بدنه اصلی با $H_{\text{backbone}}^{(L)}$ و خروجی هم‌تراز شاخه کمکی با H_{x_2} نمایش داده

شود، اتصال باقی مانده نهایی به صورت زیر است:

$$H_{\text{fused}} = H_{\text{backbone}}^{(L)} + H_{x2} \quad (3.1.9)$$

سپس H_{fused} وارد لایه نهایی DiT تا ویژگی‌های نهایی به دست آیند.

۲.۳ استراتژی آموزش و تنظیم دقیق

استراتژی آموزش DuoDiT بر ثابت نگه داشتن بدنه اصلی و آموزش اجزای شاخه کمکی مبتنی است. هدف این طراحی، کاهش تعداد پارامترهای به‌روزرسانی‌شونده در عین حفظ امکان سازگارسازی بازنمایی‌های محلی است [۴۶، ۵۴].

۱.۲.۳ مدیریت پارامترهای منجمد و آموزش‌پذیر

در این روش، بدنه اصلی مدل انتشار (DiT Backbone) که شامل لایه‌های تعبیه ورودی، بلوک‌های مبدل اصلی و لایه‌های مدولاسیون است، به طور کامل منجمد (Frozen) نگه داشته می‌شود. این کار باعث می‌شود دانش پیش‌آموزش‌دیده مدل پایه در طول تنظیم دقیق تغییر نکند [۴۶، ۵۴]. در مقابل، اجزای زیر به عنوان پارامترهای قابل آموزش (Trainable Parameters) فعال می‌شوند:

- تعبیه‌ساز پیچ شاخه $x2$: برای یادگیری بازنمایی‌های اولیه با وضوح بالا.
- توکن‌های کلاس محلی: پارامترهای یادگیرنده‌ای که بازنمایی هر گروه محلی را خلاصه می‌کنند.
- بلوک مبدل شاخه $x2$ و پروجکشن‌ها: جهت پردازش عمیق ویژگی‌های جزئیات.
- لایه خروجی (Final Layer): که امکان تطبیق نهایی خروجی مدل با فضای هدف را فراهم می‌کند.

این تفکیک پارامترها باعث می‌شود تنها 17.95 میلیون پارامتر از مجموع 690.39 میلیون پارامتر نیازمند ذخیره گرادیان و به‌روزرسانی باشند.

۲.۲.۳ مقداردهی اولیه با وزن‌های پیش‌آموزش دیده

برای مقداردهی اولیه بلوک مبدل شاخه $\times 2$ ، از وزن‌های پیش‌آموزش دیده مدل ViT-Large آموزش دیده روی ImageNet استفاده می‌شود. در صورتی که ابعاد فضای پنهان مدل DiT با ابعاد مدل ViT بارگذاری شده تفاوت داشته باشد، لایه‌های پروجکشن خطی برای تطبیق ابعاد اضافه و آموزش داده می‌شوند [۴۶، ۶۵، ۱۲، ۱۶].

۳.۲.۳ تثبیت آموزش با EMA

برای پایداری فرآیند آموزش و جلوگیری از نوسانات شدید در وزن‌ها، از روش میانگین متحرک نمایی^۱ (EMA) استفاده می‌شود. یک نسخه کپی از مدل که وزن‌های آن میانگین متحرک وزن‌های در حال آموزش است، نگهداری می‌شود و در نهایت برای تولید نمونه‌ها و ارزیابی کیفیت مورد استفاده قرار می‌گیرد [۴۶].

۴.۲.۳ الگوریتم آموزش

الگوریتم ۱ روند آموزش DuoDiT را به صورت گام‌به‌گام نشان می‌دهد. در این الگوریتم، بدنه اصلی DiT ثابت است، شاخه $\times 2$ با توکن‌های کلاس محلی آموزش داده می‌شود، و ادغام دو جریان پس از آخرین بلوک بدنه اصلی انجام می‌گیرد.

۵.۲.۳ کارایی پارامتری

جدول ۳.۲.۱ تحلیل کلان تعداد پارامترهای قابل آموزش در معماری DuoDiT را نشان می‌دهد. با منجمد نگه داشتن بدنه اصلی DiT-XL/2 و آموزش فقط شاخه دوم، توکن‌های کلاس محلی،

¹Exponential Moving Average

Algorithm 1 Parameter-Efficient Training Loop for DuoDiT

Require: Pre-trained DiT Backbone θ_{frozen} , Trainable x2-stream parameters ϕ ,

Dataset $\mathcal{D}$, Learning Rate η

- 1: Initialize Second Stream Expert ViT block with pre-trained weights
 - 2: Freeze all parameters in θ_{frozen}
 - 3: **while** not converged **do**
 - 4: Sample batch of images $x_0 \sim \mathcal{D}$ and class labels y
 - 5: Sample time steps $t \sim \text{Uniform}(1, T)$
 - 6: Sample noise $\epsilon \sim \mathcal{N}(0, I)$
 - 7: Compute noisy image $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$
 - 8: Extract final frozen-backbone features $h_{\text{backbone}}^{(L)} = \mathcal{F}(x_t, t, y; \theta_{\text{frozen}})$
 - 9: Extract high-resolution x2 tokens $h_{x2} = \mathcal{E}_{x2}(x_t; \phi_{\text{embed}})$
 - 10: Use (modulated) Second Stream features $h'_{x2} = h_{x2}$
 - 11: Group x2 tokens in sets of four and append local class tokens
 - 12: Process grouped sequence through Expert ViT block
 - 13: Extract local class-token positions and project them to DiT hidden dimension: h_{cls}
 - 14: Fuse after the final backbone block: $h_{\text{fused}} = h_{\text{backbone}}^{(L)} + h_{\text{cls}}$
 - 15: Predict noise $\epsilon_{\theta} = \text{FinalLayer}(h_{\text{fused}}; \phi_{\text{out}})$
 - 16: Compute Loss $\mathcal{L} = \|\epsilon - \epsilon_{\theta}\|^2$
 - 17: Update $\phi \leftarrow \phi - \eta \nabla_{\phi} \mathcal{L}$
 - 18: Update EMA parameters $\phi_{\text{ema}} \leftarrow 0.9999\phi_{\text{ema}} + 0.0001\phi$
 - 19: **end while**
-

پروجکشن‌ها و لایه خروجی، تعداد پارامترهای آموزش‌پذیر به ۱۷.۹۵ میلیون از ۶۹۰.۳۹ میلیون پارامتر کل محدود می‌شود. این کاهش در تعداد وزن‌های به‌روزرسانی‌شونده، امکان اجرای تنظیم دقیق پارامتر-کارا را با هزینه حافظه و زمان کمتر فراهم می‌کند [۴۶، ۵۴].

جدول ۳.۲.۱: تحلیل پیچیدگی مدل و تفکیک پارامترهای قابل آموزش

Component	Parameters (M)	Trainable
Frozen DiT-XL/2 Backbone	672.44	False
Trainable DuoDiT Components	17.95	True
Total Parameters	690.39	

۳.۳ تابع هزینه

فرض کنید x_t نمونه نویزی در گام زمانی t و y برچسب کلاس باشد. بدنه اصلی منجمد با پارامترهای θ خروجی آخرین بلوک خود را به صورت زیر تولید می‌کند [۴۶، ۱۴]:

$$H_{\text{backbone}}^{(L)} = \mathcal{F}_{\theta}(x_t, t, y), \quad H_{\text{backbone}}^{(L)} \in \mathbb{R}^{N \times T \times D}. \quad (3.3.10)$$

شاخه x2 همان ورودی نویزی را با اندازه پیچ کوچک‌تر پردازش می‌کند و توالی بلندتری به دست می‌دهد:

$$Z_{x2} = \mathcal{E}_{x2}(x_t), \quad Z_{x2} \in \mathbb{R}^{N \times 4T \times D}. \quad (3.3.11)$$

در آموزش اصلی این پژوهش، شاخه کمکی بدون مدولاسیون FiLM وارد مرحله جمع می‌شود:

$$\tilde{Z}_{x2} = Z_{x2}. \quad (3.3.12)$$

توکن‌های شاخه کمکی مطابق رابطه ۳.۱.۴ در گروه‌های چهارتایی قرار می‌گیرند، توکن کلاس محلی به هر گروه افزوده می‌شود و توالی حاصل از بلوک مبدل شاخه کمکی عبور می‌کند:

$$U = \mathcal{T}_{\phi}(\text{Flatten}([\text{Group}(\tilde{Z}_{x2}); C])), \quad U \in \mathbb{R}^{N \times 5T \times D}. \quad (3.3.13)$$

با انتخاب خروجی های متناظر با توکن های کلاس، توالی شاخه کمکی به طول T کاهش می یابد:

$$H_{x2} = \text{SelectClassToken}(U), \quad H_{x2} \in \mathbb{R}^{N \times T \times D}. \quad (3.3.14)$$

در نهایت، خروجی شاخه کمکی پس از هم تراز سازی ابعاد، به خروجی آخرین بلوک بدنه اصلی افزوده می شود و لایه نهایی نویز را پیش بینی می کند:

$$\epsilon_{\theta, \phi}(x_t, t, y) = \text{FinalLayer}_{\phi}(H_{\text{backbone}}^{(L)} + H_{x2}). \quad (3.3.15)$$

تابع هزینه آموزشی همان خطای رایج پیش بینی نویز در مدل های انتشار است [۴۶، ۱۴]:

$$\mathcal{L}_{\text{DuoDiT}} = \mathbb{E}_{x_0, t, \epsilon, y} [\|\epsilon - \epsilon_{\theta, \phi}(x_t, t, y)\|_2^2]. \quad (3.3.16)$$

در این رابطه ها، θ ثابت است و فقط پارامترهای ϕ ، شامل تعبیه ساز شاخه x_2 ، توکن های کلاس محلی، بلوک مبدل شاخه کمکی، پروجکشن ها و لایه نهایی، به روزرسانی می شوند.

۴.۳ جمع بندی

در این فصل، معماری DuoDiT برای تنظیم دقیق پارامتر – کارای مدل DiT معرفی شد. روش نهایی شامل یک بدنه اصلی منجمد و یک شاخه وضوح بالا است که خروجی آن با مکانیزم توکن کلاس محلی از $4T$ توکن به T توکن کاهش می یابد. سپس خروجی هم تراز شاخه کمکی پس از آخرین بلوک بدنه اصلی با جریان اصلی جمع شده و وارد لایه نهایی می شود. در این ساختار، راهبردهای ساده تری مانند پروجکشن خطی، بیشینه گیری و کمینه گیری به عنوان مبنای مقایسه ای در نظر گرفته شده اند، اما معماری اصلی گزارش شده در این پایان نامه بر تجمیع مبتنی بر توکن کلاس محلی و ادغام نهایی `x2_final_fuse` متکی است.

فصل ۴

آزمایش‌ها، نتایج و تحلیل

در این فصل، معماری DuoDiT در سناریوی تولید تصویر شرطی روی ImageNet-1K ارزیابی می‌شود. هدف اصلی، سنجش این پرسش است که آیا افزودن یک شاخه دوم با وضوح توکنی بالاتر، در حالی که بدنه اصلی DiT-XL/2 منجمد باقی می‌ماند، می‌تواند کیفیت توزیعی و ادراکی تولید را با بودجه پارامتری کوچک بهبود دهد یا خیر. به همین منظور، نتایج DuoDiT با DiT-XL/2، LightningDiT و FineDiffusion مقایسه می‌شود [۴۴، ۷۰، ۴۶].

۱.۴ پیکربندی آزمایش

ارزیابی اصلی بر روی تولید شرطی ImageNet-1K در وضوح 256×256 انجام شده است [۱۲]، [۵۱]. مطابق پروتکل FID-50K، تعداد ۵۰,۰۰۰ تصویر تولید می‌شود؛ برچسب هر نمونه به صورت یکنواخت از میان ۱۰۰۰ کلاس ImageNet انتخاب می‌گردد و سپس کیفیت نمونه‌ها در برابر آمار مرجع ImageNet محاسبه می‌شود.

۱.۱.۴ جزئیات پیاده‌سازی

مدل پایه در تمام آزمایش‌ها DiT-XL/2 است که شامل ۲۸ بلوک مبدل، بعد پنهان ۱۱۵۲ و ۱۶ سر توجه است. شاخه اصلی با اندازه پیچ ۲ روی فضای نهان عمل می‌کند، در حالی که شاخه دوم DuoDiT اندازه پیچ ۱ دارد و بنابراین توکن‌های ریزدانه‌تری تولید می‌کند. بلوک خبره ViT در شاخه دوم از وزن‌های از پیش آموزش دیده vit_large_patch16_224 مقداردهی اولیه شده و برای تطبیق بعد ۱۰۲۴ این بلوک با بعد ۱۱۵۲ در DiT-XL/2، پروجکشن‌های خطی ورودی و خروجی آموزش داده می‌شوند [۴۶، ۶۵، ۱۶].

تصاویر ورودی با برش مرکزی، وارونگی تصادفی افقی و نرمال‌سازی به بازه $[-1, 1]$ پیش‌پردازش می‌شوند. سپس تصاویر با استفاده از رمزگذار sd-vae-ft-ema به فضای نهان $32 \times 32 \times 4$ نگاشت شده و ضریب مقیاس 0.18215 اعمال می‌شود [۴۹]. بهینه‌ساز AdamW با نرخ یادگیری ثابت 10^{-4} ، اندازه دسته سراسری ۲۵۶، ضرایب $\beta_1 = 0.9$ و $\beta_2 = 0.999$ و وزن‌کاهی صفر استفاده شده است [۳۸]. مدل DuoDiT-200 برای ۲۰۰ دوره آموزش داده شده و نسخه DuoDiT-57 به‌عنوان نقطه میانی آموزش نیز گزارش می‌شود.

برای پایداری آموزش، میانگین متحرک نمایی (EMA) با ضریب فروپاشی 0.9999 روی وزن‌های آموزش‌پذیر اعمال شده است [۲۵، ۴۸]. در نمونه‌برداری، از DDPM با ۲۵۰ گام و ضریب هدایت بدون طبقه‌بند $CFG=1.5$ استفاده شده است [۲۶، ۲۵]. احتمال حذف برچسب کلاس در آموزش برابر 0.1 است تا نمونه‌برداری شرطی و غیرشرطی برای CFG پشتیبانی شود.

۲.۴ نتایج کمی

جدول ۴.۲.۲ مقایسه اصلی مدل‌ها را نشان می‌دهد. LightningDiT بهترین مقدار FID گزارش شده را دارد، اما DuoDiT-200 در KID و LIPS-Mean بهترین عملکرد را میان مدل‌های مقایسه‌شده ثبت می‌کند. این نتیجه نشان می‌دهد شاخه دوم DuoDiT بیشتر از آنکه صرفاً یک تنظیم پارامتری

جدول ۴.۱.۱: خلاصه ابرپارامترها و تنظیمات مورد استفاده در آموزش و نمونه‌برداری DuoDiT.

Category	Parameter	Value
Model	Architecture	DiT-XL/2
	Transformer Depth	28
	Hidden Dimension	1152
	Attention Heads	16
	MLP Ratio	4.0
	Main Patch Size	2
	Second Stream Patch Size	1
Training	Image Resolution	256×256
	VAE	sd-vae-ft-ema
	Diffusion Steps	1000
	Optimizer	AdamW
	Learning Rate	1×10^{-4}
	Global Batch Size	256
	Epochs	200
	Seed	0
	Label Dropout	0.1
Sampling	DDPM Steps	250
	CFG Scale	1.5

سطحی باشد، می‌تواند در کیفیت ادراکی و شباهت توزیعی مبتنی بر KID اثر بگذارد.

جدول ۴.۲.۲: مقایسه کمی اصلی میان مدل‌های ارزیابی‌شده. معیارهای FID، KID و LPIPS-Mean همگی کمتر-بهرتر هستند.

Model	FID ($\downarrow$)	KID ($\downarrow$)	LPIPS-Mean ($\downarrow$)	Params/Trainable (M)
DiT-XL/2 [46]	2.270 [†]	0.0023	0.7209	675.00 [†]
LightningDiT [70]	1.350[†]	0.0016	0.7232	675.00 [†]
FineDiffusion [44]	9.674	0.0093	0.7802	685.64 / 12.15
DuoDiT-57	4.95	0.0069	0.7175	690.39 / 17.95
DuoDiT-200	2.219	0.0014	0.7162	690.39 / 17.95

مقادیر دارای [†] از گزارش رسمی مقاله یا پروژه متناظر گرفته شده‌اند. DuoDiT-57 و DuoDiT-200 معماری یکسان دارند و تفاوت آن‌ها در تعداد دوره‌های آموزش است.


جدول ۴.۲.۳: آمار تجمعی FID کلاسی را نشان می‌دهد. میانگین کلاسی DuoDiT-57 کمی بهتر از سایر مدل‌هاست، در حالی که DuoDiT-200 کمترین انحراف معیار را ثبت می‌کند. این الگو نشان می‌دهد افزایش تعداد دوره‌های آموزش، علاوه بر بهبود معیارهای اصلی، پراکندگی عملکرد کلاسی را نیز پایدارتر می‌کند.

جدول ۴.۲.۳: آمار تجمعی FID کلاسی روی کلاس‌های ارزیابی‌شده ImageNet.

Model	Mean	Std.	Range
DiT	109.4829	46.6011	27.3300–254.8514
LightningDiT	110.6087	46.2643	28.8194–254.1752
FineDiffusion	306.0911	67.4299	69.0698–807.0562
DuoDiT-57	108.5531	46.3826	26.7390–278.0763
DuoDiT-200	109.5321	46.1673	27.4746–253.7685

۳.۴ نتایج کیفی

شکل ۴.۳.۱ نمونه‌هایی از خروجی‌های DuoDiT-200 را برای کلاس‌های مختلف نشان می‌دهد.



شکل ۴.۳.۱: نمونه‌های تصویری تولیدشده توسط DuoDiT-200 روی کلاس‌های مختلف ImageNet.

۴.۴ مطالعه انسانی

برای تکمیل معیارهای خودکار، یک مطالعه انسانی میان نمونه‌های DuoDiT و LightningDiT انجام شده است. این مطالعه روی کلاس‌هایی از Mini-ImageNet، به عنوان زیرمجموعه‌ای فشرده از ImageNet، اجرا شده و شامل ۱۳ شرکت‌کننده است [۵۱]. هر شرکت‌کننده ۳۰۰ مقایسه زوجی انجام داده و در مجموع ۳۹۰۰ پاسخ ثبت شده است.

جدول ۴.۴.۴: نتایج مطالعه ترجیح انسانی برای مقایسه نمونه‌های DuoDiT و LightningDiT.

DuoDiT	LightningDiT	Tie	Total	DuoDiT Pref.
1593 (40.85%)	1398 (35.85%)	909 (23.31%)	3900	53.26%

مقدار DuoDiT Pref. از مقایسه‌های غیرمساوی محاسبه شده است؛ یعنی نسبت انتخاب‌های DuoDiT به مجموع انتخاب‌های DuoDiT و LightningDiT.

نتایج جدول ۴.۴.۴ نشان می‌دهد با وجود برتری LightningDiT در FID کلی، نمونه‌های DuoDiT در قضاوت انسانی سهم بیشتری از انتخاب‌های غیرمساوی را به دست آورده‌اند. این اختلاف با نتیجه LPIPS-Mean همسو است و نشان می‌دهد شاخه وضوح بالا می‌تواند روی ویژگی‌هایی اثر بگذارد که در ادراک انسانی مهم هستند.

۵.۴ هزینه محاسباتی و کارایی پارامتری

جدول ۴.۵.۵ هزینه محاسباتی DuoDiT-200 را با FineDiffusion مقایسه می‌کند. FineDiffusion تعداد پارامتر آموزش‌پذیر کمتری دارد، اما در تنظیم پروفایل شده زمان هر دوره و مصرف حافظه بیشتری ثبت کرده است. در مقابل، DuoDiT-200 با 17.95M پارامتر آموزش‌پذیر، زمان هر دوره 13m و مصرف حافظه اوج 2.91GB را نشان می‌دهد.

جدول ۴.۵.۵: مقایسه هزینه محاسباتی و حافظه‌ای DuoDiT و FineDiffusion در تولید 256×256 [۴۴].

Method	GFLOPs	Params	Trainable	Time/Epoch	VRAM
DuoDiT-200	267.10	690.39M	17.95M	13m	2.91GB
FineDiffusion	228.84	685.64M	12.15M	22m	3.19GB

۶.۴ مطالعات حذفی

مطالعات حذفی برای جدا کردن اثر انتخاب‌های معماری انجام شده‌اند. این بخش شامل نتایج مربوط به راهبردهای تجمیع ویژگی، عمق شاخه دوم و نقش استفاده از ویژگی‌های ViT و ضریب CFG است. نتایج تجمیع ویژگی در سناریوی کنترل شده پنج کلاس ۹۷۲ تا ۹۷۶ گزارش شده‌اند تا اثر مکانیزم توکن کلاس محلی به صورت مستقیم با روش‌های ساده‌تر مقایسه شود.

۱.۶.۴ راهبردهای تجمیع ویژگی

جدول ۴.۶.۶ نشان می‌دهد که توکن کلاس محلی در مقایسه با میانگین‌گیری، بیشینه‌گیری و پروجکشن خطی بهترین مقدار را در هر سه معیار به دست می‌آورد. این نتیجه با انگیزه معماری سازگار است: تجمیع ثابت، همه نواحی مکانی را با قاعده یکسان خلاصه می‌کند، در حالی که توکن کلاس محلی از مکانیزم خود توجه برای استخراج محتوا-آگاه اطلاعات هر گروه چهار توکنی استفاده می‌کند.

جدول ۴.۶.۶: مطالعه حذفی راهبردهای تجمیع برای هم‌تراز کردن توکن‌های شاخه دوم با شبکه توکنی DiT.

Strategy	FID ($\downarrow$)	KID ($\downarrow$)	LPIPS-Mean ($\downarrow$)
Average Pooling	142.31	0.0452	0.7489
Max Pooling	140.85	0.0438	0.7412
Linear Projection	138.92	0.0415	0.7352
Local CLS Token	135.78	0.0396	0.7018

۲.۶.۴ عمق شاخه دوم

جدول ۴.۶.۷ هزینه اضافه کردن بلوک‌های بیشتر در شاخه دوم را نشان می‌دهد. افزایش عمق از یک بلوک به دو و چهار بلوک، GFLOPs، زمان هر دوره و مصرف حافظه را افزایش می‌دهد. بنابراین تنظیم یک بلوک، نقطه تعادل مناسبی میان ظرفیت محلی و هزینه محاسباتی فراهم می‌کند.

جدول ۴.۶.۷: مطالعه حذفی عمق شاخه دوم از نظر محاسبات، زمان و حافظه.

Variant	GFLOPs	Time/Epoch	VRAM
1 block	267.10	13mins	2.91GB
2 blocks	299.32	15mins	2.99GB
4 blocks	363.75	26mins	3.15GB

۳.۶.۴ ویژگی‌های شاخه دوم و ضریب CFG

جدول ۴.۶.۸ دو نوع تحلیل را نشان می‌دهد. در بخش نخست، استفاده از ویژگی‌های بلوک ViT نسبت به اتصال ساده عملکرد کمی بهتری ثبت می‌کند. در بخش دوم، ضریب $CFG=1.0$ در این تنظیم حذفی بهترین FID و KID را دارد و افزایش ضریب تا $4/0$ باعث افت توزیعی می‌شود. با این حال، تنظیم نهایی مقاله برای ارزیابی اصلی از $CFG=1.5$ استفاده می‌کند تا تعادل وفاداری شرطی و تنوع نمونه‌ها حفظ شود.

جدول ۴.۶.۸: مطالعه حذفی استفاده از ویژگی‌های شاخه دوم و مقدار ضریب CFG.

Variant	FID ($\downarrow$)	KID ($\downarrow$)
Skip Connection	216.7914	0.0512
ViT block features	215.7946	0.0503
CFG = 1.0	210.3986	0.04142
CFG = 2.0	215.7946	0.05030
CFG = 4.0	230.0816	0.06270

۷.۴ بحث

نتایج این فصل نشان می‌دهد DuoDiT یک مسیر مکمل برای تنظیم دقیق پارامتر-کارای DiT فراهم می‌کند. بدنه منجمد DiT ساختار معنایی و دانش تولیدی پیش‌آموزش‌دیده را حفظ می‌کند، در حالی که شاخه دوم با اندازه پچ کوچک‌تر ویژگی‌های محلی بیشتری را در اختیار مدل قرار می‌دهد. مکانیزم توکن کلاس محلی نیز این ویژگی‌های ریزدانه را بدون افزایش طول توالی بدنه اصلی، به شبکه توکنی DiT منتقل می‌کند.

برتری DuoDiT-200 در KID و LPIPS-Mean نشان می‌دهد اثر شاخه دوم بیشتر در شباهت توزیعی پایدار و کیفیت ادراکی ظاهر می‌شود. از سوی دیگر، مقدار FID مدل همچنان از LightningDiT بالاتر است؛ بنابراین ادعای این پایان‌نامه جایگزینی کامل روش‌های آموزش بزرگ‌مقیاس نیست، بلکه ارائه یک مسیر سبک برای تقویت مدل منجمد است. محدودیت اصلی آن است که شاخه محلی در برخی نمونه‌های دارای مرزهای مبهم یا بافت‌های بسیار متراکم ممکن است ساختار محلی نادرست را نیز تقویت کند. بررسی شرط‌گذاری اختیاری FiLM و طراحی چندمقیاسی شاخه دوم می‌تواند در پژوهش‌های آینده برای کاهش این خطاها مطالعه شود.

فصل ۵

نتیجه‌گیری و پیشنهادها

۱.۵ خلاصه و دستاوردها

در این پژوهش، معماری DuoDiT به عنوان یک رویکرد دوجریانی برای تنظیم دقیق پارامتر-کارای مدل‌های انتشار مبتنی بر مبدل معرفی شد. هسته اصلی روش، حفظ بدنه پیش‌آموزش‌دیده DiT-XL/2 به صورت منجمد و افزودن یک شاخه دوم سبک با وضوح توکنی بالاتر است. این شاخه از طریق توکن‌های کلاس محلی با جریان اصلی هم‌تراز می‌شود و بدون آموزش مجدد کامل بدنه، امکان تزریق ویژگی‌های محلی و ریزدانه را فراهم می‌کند [۴۶، ۵۴].

مهم‌ترین دستاوردهای این پژوهش عبارتند از:

۱. معماری دوجریانی DuoDiT: طراحی یک شاخه دوم با اندازه پچ کوچک‌تر که در کنار بدنه اصلی منجمد عمل می‌کند و ویژگی‌های محلی را پیش از ادغام با جریان اصلی استخراج می‌نماید.

۲. مکانیزم توکن کلاس محلی: یک راهبرد محتوا-آگاه برای تجمیع ویژگی‌های شاخه دوم که در مطالعه حذفی نسبت به میانگین‌گیری، بیشینه‌گیری و پروجکشن خطی عملکرد بهتری ثبت

کرده است.

۳. ارزیابی بزرگ‌مقیاس: ارزیابی روی ImageNet-1K نشان داد که DuoDiT-200 با 17.95M پارامتر آموزش‌پذیر از مجموع 690.39M پارامتر، به $FID=2.219$ ، $KID=0.0014$ و LPIPS-Mean=0.7162 می‌رسد [۷۴، ۳، ۲۴].

۴. شواهد ادراکی انسانی: در مطالعه ترجیح انسانی میان DuoDiT و LightningDiT، مدل پیشنهادی در 53.26% مقایسه‌های غیرمساوی ترجیح داده شد، که با بهبود LPIPS-Mean همسو است [۷۰].

۲.۵ پیشنهادهایی برای پژوهش‌های آینده

بر اساس یافته‌های این پژوهش، مسیرهای زیر برای تحقیقات آتی پیشنهاد می‌شود:

۱. بررسی شرط‌گذاری اختیاری FiLM: فعال‌سازی و ارزیابی کنترل‌شده FiLM در تنظیمات شرطی ریزدانه‌تر می‌تواند نشان دهد آیا همگام‌سازی مستقیم شاخه دوم با زمان و کلاس بهبود معناداری ایجاد می‌کند یا خیر [۴۷].

۲. شاخه‌های کمکی چندمقیاسی: توسعه بیش از یک شاخه وضوح بالا می‌تواند به مدل اجازه دهد جزئیات محلی را در چند مقیاس مکانی همزمان پردازش کند.

۳. کاهش هزینه استنتاج: ترکیب DuoDiT با روش‌هایی مانند کوانتیزاسیون پس از آموزش یا مسیرهای محاسباتی پویا می‌تواند هزینه اجرای مدل را کاهش دهد [۷۲].

۴. تعمیم به تولید متن-به-تصویر و ویدئو: استفاده از شاخه دوم در مدل‌های شرطی متنی یا ویدئویی می‌تواند نشان دهد آیا این ایده فراتر از تولید کلاسی ImageNet نیز مفید است یا خیر [۲۷، ۴۹].

۵. جایگزینی بدنه اصلی/خبره: جایگزینی اجزای اصلی مدل، مانند بدنه اصلی یا خبره، با مدل‌های

دیگر می‌تواند منجر به بهبود عملکرد و کاهش هزینه محاسباتی شود.

در مجموع، DuoDiT نشان می‌دهد که اصلاحات معماری هدفمند می‌توانند مسیر مؤثری

برای تنظیم دقیق پارامتر-کارای مدل‌های انتشار مبتنی بر مبدل باشند. این روش جایگزین آموزش

بزرگ مقیاس مدل‌های قدرتمندتر نیست، بلکه راهکاری برای بهره‌گیری از دانش یک بدنه منجمد و

افزودن ظرفیت محلی با هزینه محدود فراهم می‌کند.

کتاب نامه

- [1] Fan Bao, Shen Nie, Kaiwen Xue, Yue Cao, Chongxuan Li, Hang Su, and Jun Zhu. All are worth words: A vit backbone for diffusion models. *arXiv preprint arXiv:2209.12152*, 2022.
- [2] Fan Bao, Shen Nie, Kaiwen Xue, Yue Cao, Chongxuan Li, Hang Su, and Jun Zhu. All are worth words: A vit backbone for diffusion models. 2023.
- [3] Mikolaj Binkowski, Dougal J. Sutherland, Michael Arbel, and Arthur Gretton. Demystifying MMD GANs. *International Conference on Learning Representations*, 2018.
- [4] He Cao, Jianan Wang, Tianhe Ren, Xianbiao Qi, Yihao Chen, Yuan Yao, and Lei Zhang. Exploring vision transformers as diffusion learners. *arXiv preprint arXiv:2212.13771v1*, 12 2022.
- [5] Chun-Fu Richard Chen, Quanfu Fan, and Rameswar Panda. Crossvit: Cross-attention multi-scale vision transformer for image classification. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 357–366, 2021.
- [6] Hang Chen, Qian Xiang, Jiaxin Hu, Meilin Ye, Chao Yu, Hao Cheng, and Lei Zhang. Comprehensive exploration of diffusion models in image generation: a survey. *Artificial Intelligence Review*, 58(99), 2025.
- [7] Junsong Chen, Jincheng Yu, Chongjian Ge, Lewei Yao, Enze Xie, Yue Wu, Zhongdao Wang, James Kwok, Ping Luo, Huchuan Lu, and Zhenguo Li.

- Pixart-alpha: Fast training of diffusion transformer for photorealistic text-to-image synthesis, 12 2023.
- [8] Junsong Chen, Jincheng Yu, Chongjian Ge, Lewei Yao, Enze Xie, Yue Wu, Zhongdao Wang, James Kwok, Ping Luo, Huchuan Lu, and Zhenguo Li. Pixart-sigma: Weak-to-strong training of diffusion transformer for 4k text-to-image generation. *arXiv preprint arXiv:2403.04692*, 2024.
- [9] Xinwang Chen, Ning Liu, Yichen Zhu, Feifei Feng, and Jian Tang. Edt: An efficient diffusion transformer framework inspired by human-like sketching. *NeurIPS 2024*, 11 2024.
- [10] Jiwoo Chung, Sangeek Hyun, and Jae-Pil Heo. Style injection in diffusion: A training-free approach for adapting large-scale diffusion models for style transfer. 2024.
- [11] Florinel-Alin Croitoru, Vlad Hondru, Radu Tudor Ionescu, and Mubarak Shah. Diffusion models in vision: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(9):10850–10869, 9 2023.
- [12] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009.
- [13] Prafulla Dhariwal and Alex Nichol. Diffusion models beat gans on image synthesis. 6 2021.
- [14] Prafulla Dhariwal and Alex Nichol. Diffusion models beat gans on image synthesis. *NeurIPS*, 11 2021.
- [15] Wei Dong, Xing Zhang, Bihui Chen, Dawei Yan, Zhijun Lin, Qingsen Yan, Peng Wang, and Yang Yang. Low-rank rescaled vision transformer fine-tuning: A residual design approach. 2024.

- [16] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 2020.
- [17] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling rectified flow transformers for high-resolution image synthesis. 3 2024.
- [18] Jin Gao, Shubo Lin, Shaoru Wang, Yutong Kou, Zeming Li, Liang Li, Congxuan Zhang, Xiaoqin Zhang, Yizheng Wang, and Weiming Hu. An experimental study on exploring strong lightweight vision transformers via masked image modeling pre-training. *arXiv preprint arXiv:2404.12210v2*, 5 2024.
- [19] Shanghua Gao, Pan Zhou, Ming-Ming Cheng, and Shuicheng Yan. Mdtv2: Masked diffusion transformer is a strong image synthesizer. 2024.
- [20] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks, 2014.
- [21] Ligong Han, Yinxiao Li, Han Zhang, Peyman Milanfar, Dimitris Metaxas, and Feng Yang. Svdiff: Compact parameter space for diffusion fine-tuning. 7 2023.
- [22] Ali Hatamizadeh, Jiaming Song, Guilin Liu, Jan Kautz, and Arash Vahdat. Diffit: Diffusion vision transformers for image generation. *arXiv preprint arXiv:2312.02139*, 2023.
- [23] Ali Hatamizadeh, Jiaming Song, Guilin Liu, Jan Kautz, and Arash Vahdat. Diffit: Diffusion vision transformers for image generation. *arXiv preprint arXiv:2312.02139v3*, 8 2024.

- [24] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. GANs trained by a two time-scale update rule converge to a local nash equilibrium. In *Advances in Neural Information Processing Systems*, pages 6626–6637, 2017.
- [25] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, pages 6840–6851, 2020.
- [26] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance, 2022.
- [27] Jonathan Ho, Tim Salimans, Alexey Gritsenko, William Chan, Mohammad Norouzi, and David J. Fleet. Video diffusion models. 2022.
- [28] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [29] Edward Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. 2021.
- [30] Yuxin Hu, Han Zhou, Ning Cao, Can Li, and Can Hu. Synthetic ct generation based on cbct using improved vision transformer cyclegan. *Scientific Reports*, 14:11455, 4 2024.
- [31] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems*, volume 35, pages 26565–26577, 2022.
- [32] Yunji Kim, Jiyoung Lee, Jin-Hwa Kim, Jung-Woo Ha, and Jun-Yan Zhu. Dense text-to-image generation with attention modulation. *arXiv preprint arXiv:2308.12964v1*, 8 2023.
- [33] Diederik P Kingma and Max Welling. Auto-encoding variational bayes, 2013.

- [34] Y. Lecun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [35] Yawei Li, Kai Zhang, Jiezhong Cao, Radu Timofte, Michele Magno, Luca Benini, and Luc Van Gool. Localvit: Analyzing locality in vision transformers. 2 2025.
- [36] Nan Liu, Shuang Li, Yilun Du, Antonio Torralba, and Joshua B. Tenenbaum. Compositional visual generation with composable diffusion models. 1 2023.
- [37] Qihao Liu, Zhanpeng Zeng, Ju He, Qihang Yu, Xiaohui Shen, and Liang-Chieh Chen. Alleviating distortion in image generation via multi-resolution diffusion models and time-dependent layer normalization. 2024.
- [38] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.
- [39] Son Thai Ly and Hien V. Nguyen. Enhancing parameter-efficient fine-tuning of vision transformers through frequency-based adaptation. 11 2024.
- [40] Jian Ma, Junhao Liang, Chen Chen, and Haonan Lu. Subject-diffusion: Open domain personalized text-to-image generation without test-time fine-tuning. 7 2024.
- [41] Xin Ma, Yaohui Wang, Xinyuan Chen, Gengyu Jia, Ziwei Liu, Yuan-Fang Li, Cunjian Chen, and Yu Qiao. Latte: Latent diffusion transformer for video generation. *Transactions on Machine Learning Research*, 3 2025.
- [42] Shentong Mo, Enze Xie, Ruihang Chu, Lanqing Hong, Matthias Nießner, and Zhenguo Li. Dit-3d: Exploring plain diffusion transformers for 3d shape generation, 2023.
- [43] Weili Nie, Hongkai Zheng, Arash Vahdat, and Anima Anandkumar. Fast training of diffusion models with masked transformers. 6 2023.

- [44] Ziyang Pan, Kun Wang, Gang Li, Feihong He, and Yongxuan Lai. Finediffusion: Scaling up diffusion models for fine-grained image generation with 10,000 classes. *Applied Intelligence*, 55(5):309, 2025.
- [45] Karran Pandey, Paul Guerrero, Matheus Gadelha, Yannick Hold-Geoffroy, Karan Singh, and Niloy Mitra. Diffusion handles: Enabling 3d edits for diffusion models by lifting activations to 3d. 2023.
- [46] William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv preprint arXiv:2212.09748*, 2022.
- [47] Ethan Perez, Florian Strub, Harm de Vries, Vincent Dumoulin, and Aaron Courville. FiLM: Visual reasoning with a general conditioning layer. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, 2018.
- [48] Boris T. Polyak and Anatoli B. Juditsky. Acceleration of stochastic approximation by averaging. *SIAM Journal on Control and Optimization*, 30(4):838–855, 1992.
- [49] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. 2022.
- [50] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [51] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C. Berg, and Li Fei-Fei. ImageNet Large Scale Visual Recognition Challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.
- [52] Simo Ryu. Low-rank adaptation for fast text-to-image diffusion fine-tuning. GitHub repository, 2023.

- [53] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S. Sara Mahdavi, Rapha Gontijo Lopes, Tim Salimans, Jonathan Hoy, David J Fleety, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. 5 2022.
- [54] James Seale Smith, Yen-Chang Hsu, Lingyu Zhang, Ting Hua, Zsolt Kira, Yilin Shen, and Hongxia Jin. Continual diffusion: Continual customization of text-to-image diffusion with c-lora. 5 2024.
- [55] Jascha Sohl-Dickstein, Eric A. Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pages 2256–2265. PMLR, 2015.
- [56] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2021.
- [57] Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [58] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021.
- [59] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017.
- [60] Jingdong Wang, Ke Sun, Tianheng Cheng, Borui Jiang, Chaorui Deng, Yang Zhao, Dong Liu, Yadong Mu, Mingkui Tan, Xinggang Wang, and Wenyu Liu. Deep high-resolution representation learning for visual recognition. *IEEE*

- Transactions on Pattern Analysis and Machine Intelligence*, 43(10):3349–3364, 2020.
- [61] Lezhong Wang, Jeppe Revall Frisvad, Mark Bo Jensen, and Siavash Arjomand Bigdeli. Stereodiffusion: Training-free stereo image generation using latent diffusion models. 6 2024.
- [62] Yaohui Wang, Xinyuan Chen, Xin Ma, Shangchen Zhou, Ziqi Huang, Yi Wang, Ceyuan Yang, Yinan He, Jiashuo Yu, Peiqing Yang, Yuwei Guo, Tianxing Wu, Chenyang Si, Yuming Jiang, Cunjian Chen, Chen Change Loy, Bo Dai, Dahua Lin, Yu Qiao, and Ziwei Liu. Lavie: High-quality video generation with cascaded latent diffusion models. 9 2023.
- [63] Zhendong Wang, Yifan Jiang, Yadong Lu, Yelong Shen, Pengcheng He, Weizhu Chen, Zhangyang Wang, and Mingyuan Zhou. In-context learning unlocked for diffusion models. *arXiv preprint arXiv:2305.01115v2*, 10 2023.
- [64] ZiDong Wang, Zeyu Lu, Di Huang, Cai Zhou, Wanli Ouyang, and Lei Bai. Fitv2: Scalable and improved flexible vision transformer for diffusion model. *arXiv preprint arXiv:2410.13925v1*, 10 2024.
- [65] Ross Wightman. Pytorch image models. GitHub repository, 2019.
- [66] Enze Xie, Lewei Yao, Han Shi, Zhili Liu, Daquan Zhou, Zhaoqiang Liu, Jiawei Li, and Zhenguo Li. Diffit: Unlocking transferability of large diffusion models via simple parameter-efficient fine-tuning. 7 2023.
- [67] Xuan Xu, Saarthak Kapse, Rajarsi Gupta, and Prateek Prasanna. Vit-dae: Transformer-driven diffusion autoencoder for histopathology image analysis. 4 2023.
- [68] Menglin Yang, Jialin Chen, Yifei Zhang, Jiahong Liu, Jiasheng Zhang, Qiyao Ma, Harshit Verma, Qianru Zhang, Min Zhou, Irwin King, and Rex Ying. Low-rank adaptation for foundation models: A comprehensive review. *IEEE TRANSACTION MANUSCRIPT (WORK IN PROGRESS)*, 12 2024.

- [69] Xiulong Yang, Shengju Sun, Nhan Do, Ce Yang, Wonjun Jang, and Ruslan Salakhutdinov. Your vit is secretly a hybrid discriminative-generative diffusion model. *arXiv preprint arXiv:2208.07791*, 2022.
- [70] Jingfeng Yao, Bin Yang, and Xinggang Wang. Reconstruction vs. generation: Taming optimization dilemma in latent diffusion models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 15703–15712, 2025.
- [71] Yao Yao, Peiyan Zhang, Zechun Liu, Zhengkai Jiang, Haonong Zhu, Xuesong Yin, and Kwang-Ting Cheng. Lavin-dit: Large vision diffusion transformer, 2024.
- [72] Lei Zhang, Zhaowei Chen, Yiming Wu, Ruihan Zhang, Peng Liang, Yidong Li, and Xiaogang Wang. Q-dit: Accurate post-training quantization for diffusion transformers, 2024.
- [73] Pengchuan Zhang, Xiyang Dai, Jianwei Yang, Bin Xiao, Lu Yuan, Lei Zhang, and Jianfeng Gao. Multi-scale vision longformer: A new vision transformer for high-resolution image encoding. 5 2021.
- [74] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 586–595, 2018.
- [75] Taolin Zhang, Jiawang Bai, Zhihe Lu, Dongze Lian, Genping Wang, Xinchao Wang, and Shu-Tao Xia. Parameter-efficient and memory-efficient tuning for vision transformer: A disentangled approach. 7 2024.
- [76] Wangbo Zhao, Yizeng Han, Jiasheng Tang, Kai Wang, Hao Luo, Yibing Song, Gao Huang, Fan Wang, and Yang You. Dydit++: Dynamic diffusion transformers for efficient visual generation. 4 2025.

- [77] Wangbo Zhao, Yizeng Han, Jiasheng Tang, Kai Wang, Yibing Song, Gao Huang, Fan Wang, and Yang You. Dynamic diffusion transformer. 2024.
- [78] Xiaosheng Zhao, Yuan-Sen Ting, Kangning Diao, and Yi Mao. Can diffusion model conditionally generate astrophysical images? *Monthly Notices of the Royal Astronomical Society*, pages 1699–1712, 9 2023.

Abstract

Diffusion transformer models, such as DiT, provide high quality in class-conditional image generation, but fully fine-tuning them for new domains or requirements is costly in terms of memory, training time, and storage. This thesis introduces DuoDiT as a parameter-efficient fine-tuning architecture for DiT models. In this architecture, the main DiT-XL/2 backbone remains frozen, while a second branch with a smaller patch size extracts local and fine-grained features. To align this branch with the backbone tokens, DuoDiT uses a local class-token mechanism that summarizes each spatial group of fine-grained tokens in a content-aware manner. The main evaluation is performed on 50,000 images generated conditionally on the ImageNet-1K dataset at 256×256 resolution. DuoDiT-200, with 17.95M trainable parameters out of 690.39M total parameters, achieves FID=2.219, KID=0.0014, and LPIPS-Mean=0.7162. In addition, a human study shows that DuoDiT samples are preferred over LightningDiT in 53.26% of the comparisons. The results indicate that adding a lightweight high-resolution pathway can improve perceptual quality and fine-tuning efficiency without fully retraining the model.

Keywords: Vision transformers, diffusion models, local and global features, feature aggregation, parameter-efficient fine-tuning



T. M. U.

Improving Diffusion Models Based on Vision Transformers for Image Generation

A Thesis Presented for the Degree of
Master of Science (Computer Science)

Faculty of Mathematical Sciences

Tarbiat Modares University

by

Mostafa Shahbazi Dill

Supervisor

Dr. Mansoor Rezghi Ahaq

Summer 2026